



Lifelong Learning em Tecnologia, Dados e Negócios

Documentação - Hackaton 2025

CLARO - Modelo de Behaviour Global

Versão: Final

ÚLTIMA ATUALIZAÇÃO: 12/03/2026

Líder do Projeto: Pedro

Analista de dados: Franciele Moritz

Cientistas de Dados: Pedro.

Engenheiros de Dados: Marcos, Roberto

link do github: <https://github.com/masdesouza/hackathon2025>

1. Contexto e Problema de Negócio

A Claro é uma das principais empresas de telecomunicações do país, com atuação nacional e um portfólio diversificado de produtos, incluindo telefonia móvel, banda larga, TV por assinatura e serviços digitais. Ao longo do relacionamento, seus clientes interagem com a companhia por diferentes produtos, planos e canais, gerando históricos ricos e heterogêneos de consumo, pagamento e comportamento.

Dentro desse ecossistema, a **base de clientes pré-pagos** desempenha um papel estratégico como porta de entrada para o relacionamento com a marca. Trata-se de uma base numerosa, dinâmica e com grande potencial de monetização ao longo do ciclo de vida do cliente.

Um dos desafios centrais da companhia é **expandir a base de clientes em planos controle de forma sustentável**, equilibrando crescimento, rentabilidade e risco. A migração indiscriminada de clientes pré-pagos para planos controle pode gerar aumento de inadimplência, pressão sobre margens e deterioração da carteira. Por outro lado, uma abordagem excessivamente conservadora pode resultar em perda de oportunidades comerciais relevantes.

Nesse contexto, o desafio de negócio consiste em **identificar, dentro da base pré-paga, quais clientes apresentam maior probabilidade de se manterem adimplentes após a migração para o plano controle**, permitindo que as ofertas sejam direcionadas de forma mais eficiente, segura e rentável.

2. Objetivo do Projeto

O objetivo principal deste projeto é **desenvolver um Modelo de Behavior, na Visão Unificada do Cliente (CPF)**, capaz de **estimar o risco de inadimplência de clientes pré-pagos no processo de migração para o plano controle**.

Esse modelo tem como finalidade apoiar decisões estratégicas e operacionais da Claro, contribuindo para:

- Redução do risco de crédito associado às migrações;
- Aumento da eficiência na alocação de ofertas de planos controle;
- Melhoria da rentabilidade da carteira;
- Sustentação do crescimento da base controle com qualidade.

O modelo foi concebido como um **instrumento de apoio à decisão**, não apenas como uma ferramenta preditiva isolada, mas como parte de uma estratégia integrada de gestão de risco e expansão comercial.

3. Abordagem Analítica e Conceitual

A abordagem adotada parte do princípio de que **o risco de inadimplência na migração não é explicado apenas por informações cadastrais ou pontuais**, mas principalmente pelo **comportamento histórico do cliente**, observado ao longo do tempo.

Dessa forma, o projeto se apoia em três pilares centrais:

1. **Visão longitudinal do cliente**, considerando histórico de uso, pagamentos, atrasos e recargas;
2. **Granularidade CPF + Safra**, permitindo observar evolução comportamental ao longo do tempo;
3. **Separação clara entre comportamento estrutural e efeitos temporais**, evitando viés de período.

O modelo busca capturar **padrões persistentes de comportamento**, que indiquem maior ou menor propensão ao risco, e não apenas eventos isolados.

4. Entendimento dos Dados

4.1 Origem e Visão Geral dos Dados

Os dados utilizados neste projeto são provenientes dos sistemas internos da Claro, consolidados em uma base analítica unificada na **visão CPF**, contemplando informações de clientes de telefonia móvel pré-paga e seus históricos recentes de interação com a companhia.

A base foi estruturada para permitir análises comportamentais em janelas temporais móveis, refletindo a dinâmica real do relacionamento do cliente com o serviço.

Os dados possuem periodicidade mensal e estão organizados por **safra**, representando o estado do cliente em cada período de observação.

4.2 Granularidade e Unidade Analítica

A unidade analítica adotada é **CPF + Safra**, o que permite:

- Acompanhar a evolução do comportamento do mesmo cliente ao longo do tempo;
- Construir variáveis históricas com janelamento temporal;
- Avaliar estabilidade e consistência de padrões de risco.

Essa granularidade é fundamental para modelos de behavior, pois evita análises estáticas e permite capturar tendências, recorrências e mudanças de perfil.

4.3 Tipos de Informações Disponíveis

A base analítica contempla informações agrupadas em grandes dimensões comportamentais, tais como:

- **Perfil de produto e migração:** tipo de plano, status de migração, indicadores de instalação;
- **Scores internos:** pontuações de risco previamente calculadas;
- **Uso e recargas:** frequência, valor, regularidade e padrões de consumo;
- **Pagamentos:** volume, timing, pontualidade, valores pagos;
- **Atrasos e inadimplência:** severidade, recorrência e histórico de atraso;
- **Informações cadastrais e demográficas agregadas.**

Essas informações foram consolidadas em uma tabela analítica única, preparada para análises exploratórias, segmentação e modelagem preditiva.

4.4 Qualidade, Volume e Estabilidade dos Dados

A base estudada apresenta **alto volume de registros**, cobrindo milhões de CPFs e múltiplas safras consecutivas, o que garante robustez estatística às análises.

As análises exploratórias indicaram:

- **Estabilidade de volume ao longo das safras**, sem rupturas abruptas;
- Ausência de evidências de deterioração estrutural da base ao longo do tempo;
- Existência de **outliers estruturais**, associados a perfis legítimos de uso intensivo.

Esses outliers foram analisados separadamente e mantidos na base por refletirem comportamentos reais e recorrentes, sem comprometer a estabilidade do modelo.

5. Definição do Público-Alvo do Modelo

5.1 Universo Inicial

O universo inicial do estudo é composto por **clientes de telefonia móvel pré-paga**, com histórico disponível para análise comportamental.

A partir desse universo, foram aplicados critérios de elegibilidade para garantir que o modelo fosse treinado e avaliado sobre clientes com histórico suficiente para inferência de risco.

5.2 Critérios de Elegibilidade

Foram considerados elegíveis para o modelo:

- Clientes com **FLAG_INSTALACAO = 1**, ou seja, efetivamente ativos e Grupo Controle;
- Clientes pertencentes aos planos **Pré, Flex e Aquisição**, conforme flag de migração;
- Clientes com histórico comportamental mínimo nas janelas analisadas;
- Inclusão de clientes inativos, para preservar a representatividade da base.
- Portanto não se excluiu nenhum grupo além dos reprovados sem target, entendendo que o modelo para este desafio precisa ser capaz de generalizar bem, e não performar em um segmento específico.

Clientes com **FLAG_INSTALACAO = 0** foram analisados separadamente para avaliação de impacto, mas não compõem o core da modelagem.

5.3 Definição do Target

O evento de interesse do modelo é o **First Payment Default (FPD)**, definido como a ocorrência de inadimplência no primeiro ciclo após a migração para o plano controle.

O FPD foi escolhido por representar:

- Um indicador crítico de risco inicial;
- Um evento diretamente associado à decisão de migração;
- Um sinal precoce de deterioração da carteira.

5.4 Safras de Desenvolvimento e Validação

As safras foram definidas da seguinte forma:

- **Desenvolvimento:** outubro/2024 a dezembro/2024; (3 safras)
- **Validação:** janeiro/2025 (1 safra)
- **Validação Out-of-Time (OOT):** fevereiro/2025 e março/2025.(2 safras)

Essa separação garante avaliação temporal adequada e reduz o risco de overfitting.

6. Caracterização do Público-Alvo

O público-alvo do modelo é composto majoritariamente por clientes:

- Aprovados e do grupo controle.

Esse público representa o **core estratégico do modelo**, pois concentra o maior trade-off entre risco e oportunidade de negócio.

7. Book de Variáveis

7.1 Recargas (Versão Analítica e Executiva)

7.1.1 Visão Executiva

Este documento descreve o Book de Variáveis de Recargas, construído com o objetivo de compreender o comportamento de consumo, recorrência, dependência de incentivos e risco de churn dos clientes pré-pagos. O book consolida informações transacionais em métricas analíticas no nível CPF–Saфра, servindo como insumo para análises exploratórias, segmentações e modelos preditivos.

7.1.2 Evolução da Base de Dados

- Base original de recargas: 100.213.651 registros, 24 colunas.
- Base score full: 3.590.459 CPFs distintos (6 safras).
- Safras analisadas (202410 a 202501): 2.462.481 CPFs válidos.
- Após cruzamento com recargas: 69.727.469 registros e 2.126.420 CPFs.

- Após exclusão de safras OOT (202502 e 202503): 62.120.782 registros e 2.085.650 CPFs.
- Safras finais de recarga: out/23 a jan/25 (16 safras).

7.1.3 Variáveis Brutas da Base

As variáveis brutas foram avaliadas quanto à cardinalidade, preenchimento e relevância analítica. Campos com valor único, predominância extrema ou alta cardinalidade sem ganho analítico não serão incluídos no book.

Campos não incluídos:

DW_NUM_CLIENTE → apresenta alta cardinalidade (>4MM), campo existe para relacionamento técnico, não para discriminar comportamento, portanto não agrega sinal analítico.

COD_TECNOLOGIA_DW → apresenta apenas 1 valor (GSM) não contribuindo para o estudo, sem poder discriminatório no período analisado.

COD_TIPO_CREDITO → 2 valores, porém com predominância quase absoluta do tipo PIN Eletrônico (PE), tornando a variável não discriminante para fins analíticos e, portanto, sem contribuição para o estudo.

COD_PROMOCAO → apenas 1 valor (-1) não contribuindo para o estudo, sem poder discriminatório no período analisado.

IND_METODO_PAGAMENTO → 2 valores, porém com predominância quase absoluta do tipo A (Automático), tornando a variável não discriminante para fins analíticos e, portanto, sem contribuição para o estudo.

Campos com missing:

Com relação aos nulos das colunas temos que 4 colunas apresentam nulos:

NUM_CPF	0
DW_NUM_NTC	0
DAT_INSERTAO_CREDITO	0
HOR_INSERTAO_CREDITO	0
DW_NUM_CLIENTE	0
COD_TECNOLOGIA_DW	0
COD_CANAL_AQUISICAO	0
COD_TIPO_CREDITO	0
COD_PROMOCAO	1.193.807

VAL_CREDITO_INSERTIDO	0
VAL_BONUS	0
VAL_REAL	0
COD_PLATAFORMA_ATU	0
COD_STATUS_PLATAFORMA	0
IND_METODO_PAGAMENTO	0
DW_PLANO_TARIFACAO	1.193.80 7
DW_TIPO_RECARGA	1.193.80 7
DW_TIPO_INSERTAO	0
DW_FORMA_PAGAMENTO	0
DW_INSTITUICAO	0
COD_GRUPO_CARTAO	0
DSC_GRUPO_CARTAO_WPP	0
FLAG_SOS	0
VALOR_SOS	57.925.5 23

7.1.3.1 Variaveis-Chave

- NUM_CPF – Identificador único do cliente
- DW_NUM_NTC – Identificador do número de telefone
- DW_NUM_CLIENTE – Identificador do número cadastral do cliente (por telefone, CPF e plano)

7.1.3.2 Variaveis Numéricas

- VAL_CREDITO_INSERTIDO – Valor da recarga principal
- VAL_BONUS – Valor de bônus concedido
- VAL_REAL – Valor total (recarga + bônus)
- VALOR_SOS – Valor da recarga emergencial

- FLAG_SOS – Valor 1 o cliente fez uso do adiantamento e 0 o cliente não fez uso

7.1.2.3 Variáveis Categóricas

- COD_TECNOLOGIA_DW – Tecnologia referente a voz, SMS e dados móveis
- COD_CANAL_AQUISICAO – Canal utilizado na recarga
- DW_PLANO_TARIFACAO – Plano vigente no momento da recarga
- DW_TIPO_INSERTAO – Tipo de inserção de crédito
- DW_FORMA_PAGAMENTO – Forma de pagamento
- COD_STATUS_PLATAFORMA – Status operacional da plataforma
- IND_METODO_PAGAMENTO – Método de pagamento (automático ou manual)
- COD_TIPO_CREDITO – Indica como o crédito entrou na linha, ou seja, a natureza da recarga
- DW_TIPO_RECARGA – Indica se a recarga é referente à franquia principal do plano Controle ou a recargas adicionais.
- COD_PROMOCAO – Indica códigos de incentivos, alteração de regras, controle
- COD_PLATAFORMA_ATU – Plataforma onde as recargas são processadas
- DW_INSTITUICAO – Instituição onde a recarga foi realizada.
- COD_GRUPO_CARTAO – identifica tecnicamente o grupo de cartão, voucher ou produto associado à recarga. Em conjunto com sua descrição (DSC_GRUPO_CARTAO_WPP), permite distinguir recargas puras de ativações promocionais, pacotes e produtos específicos.
- DSC_GRUPO_CARTAO_WPP – É a descrição do grupo de cartão / voucher / pacote associado à recarga no ecossistema WPP (Wholesale / Pré-pago).

7.1.2.4 Variáveis de Data e Hora

- DAT_INSERTAO_CREDITO – Data da recarga
- HOR_INSERTAO_CREDITO – Hora da recarga

7.1.4 Dicionário Técnico das Variáveis Criadas (1- NUM_CPF + 113 -> 114)

Variável	Definição	Fórmula / Regra	Pergunta que Responde
SAFRA_RECARGA	Safra da recarga em anomes("yyyyMM")	date_format(F.col("DAT_INSERTAO_CREDITO_DT"), "yyyyMM")	Qual o anomes da recarga?
dt_primeira_recarga	data mínima de recarga	min("DAT_INSERTAO_CREDITO_DT")	Evento mais antigo do cliente
dt_ultima_recarga	data máxima de recarga	max("DAT_INSERTAO_CREDITO_DT")	Evento mais recente do cliente
qtd_recargas	Quantidade total de recargas	COUNT(*)	Com que frequência o cliente recarrega?
vlr_total_recarga	Valor total recarregado	SUM(VAL_CREDITO_INSERTIDO)	Qual a intensidade do consumo?
vlr_medio_recarga	Valor médio por recarga	AVG(VAL_CREDITO_INSERTIDO)	O cliente recarrega valores altos ou baixos?

vlr_max_recarga	Valor máximo das recargas	max("VAL_CREDITO_INSERTIDO")	Qual o maior valor de recarga do cliente?
vlr_min_recarga	Valor mínimo das recargas	min("VAL_CREDITO_INSERTIDO")	Qual o menor valor de recarga do cliente?
qtd_telefones	Contagem distinta de números de telefones do cliente	countDistinct("DW_NUM_NTC")	Quantos telefones sustentam o consumo?
qtd_rec_madrugada	quantidade de recargas das 0-5 horas da madrugada	sum(F.when(F.col("fx_hora") == "01_Madrugada", 1).otherwise(0))	Cliente carrega a recarga em qual horário?
qtd_rec_manha	quantidade de recargas das 6-11 horas da manhã	sum(F.when(F.col("fx_hora") == "02_Manha", 1).otherwise(0))	Cliente carrega a recarga em qual horário?
qtd_rec_tarde	quantidade de recargas das 12-17 horas da tarde	sum(F.when(F.col("fx_hora") == "03_Tarde", 1)	Cliente carrega a recarga em qual horário?
qtd_rec_noite	quantidade de recargas das 18-23 horas da noite	sum(F.when(F.col("fx_hora") == "04_Noite", 1).otherwise(0))	Cliente carrega a recarga em qual horário?
fx_hora_dominante	hora que o cliente mais fez recarga	df_counts = df.groupBy("NUM_CPF", "SAFRA_RECARGA", "fx_hora").count() w = Window.partitionBy("NUM_CPF", "SAFRA_RECARGA").orderBy(F.col("count").desc()) df_hora_dom = (df_counts .withColumn("rn", F.row_number().over(w)) .filter(F.col("rn") == 1) .select("NUM_CPF", "SAFRA_RECARGA", F.col("fx_hora")	Cliente carrega a recarga em qual horário?
qtd_rec_sos	quantidade de recargas emergenciais realizadas (adiantamentos de crédito)	sum("FLAG_SOS")	Usa SOS por emergência ou padrão?
vlr_medio_rec_sos	média dos valores das recargas emergenciais	avg(F.when(F.col("FLAG_SOS") == 1, F.col("VALOR_SOS")))	Usa SOS por emergência ou padrão?
flg_uso_sos	0 não fez uso e 1 fez uso da recarga emergencial	F.when(F.col("qtd_rec_sos") > 0, 1).otherwise(0)	Usa SOS por emergência ou padrão?
pct_rec_sos	Percentual de recargas SOS	qtd_rec_sos / qtd_recargas	Usa SOS por emergência ou padrão?
qtd_rec_com_bonus	quantidade de recarga com bônus	count(F.when(F.col("VAL_BONUS") > 0, True))	É dependente de bônus?
vlr_rec_com_bonus	soma dos valores das recargas com bônus	sum(F.when(F.col("VAL_BONUS") > 0, F.col("VAL_REAL")).otherwise(0))	É dependente de bônus?
vlr_total_bonus	soma do valor do bônus	sum("VAL_BONUS")	É dependente de bônus?
vlr_medio_bonus	média do valor do bônus	avg("VAL_BONUS")	É dependente de bônus?
fx_dependencia_bonus	Faixa de dependência de bônus	Regra por pct_rec_com_bonus	É dependente de bônus?
pct_rec_com_bonus	representativa da quantidade de recargas com bônus sobre a quantidade de recargas totais que o cliente efetuou	F.col("qtd_rec_com_bonus") / F.col("qtd_rec_total")	É dependente de bônus?
vlr_total_real	soma do valor do real, recarga mais bônus	sum("VAL_REAL")	Qual a intensidade do consumo?
vlr_medio_real	média do valor real, recarga mais bônus	avg("VAL_REAL")	O cliente recarrega valores altos ou baixos?

canal_principal	canal que o cliente mais fez recarga	<pre>df_canal_counts = (df .groupBy("NUM_CPF", "SAFRA_RECARGA", "COD_CANAL_AQUISICAO") .count()) w = Window.partitionBy("NUM_CPF", "SAFRA_RECARGA").orderBy(F.col("count").desc()) df_canal = (df_canal_counts .withColumn("rn", F.row_number().over(w)) .filter(F.col("rn") == 1) .select("NUM_CPF", "SAFRA_RECARGA", F.col("COD_CANAL_AQUISICAO"))</pre>	Qual o canal que o cliente mais faz recarga?
recencia_dias	Dias desde a última recarga	Data_ref - dt_ultima_recarga	O cliente está ativo?
fx_recencia	5 agrupamentos em dias (0-7, 8-15, 16-30, 31-60, 60+)	<pre>F.when(F.col("recencia_dias") <= 7, "01_0a7") .when(F.col("recencia_dias") <= 15, "02_8a15") .when(F.col("recencia_dias") <= 30, "03_16a30") .when(F.col("recencia_dias") <= 60, "04_31a60") .otherwise("05_60+")</pre>	Cliente mais ativo ou inativo?
gap_medio_recarga	Intervalo médio entre recargas	AVG(diff_datas)	O consumo é recorrente ou casual?
gap_std_recarga	desvio padrão da diferença entre a data da recarga e da recarga anterior	stddev("gap_dias")	O consumo é recorrente ou casual?
desvio_recencia	recência - gap_medio_recarga	F.col("recencia_dias") - F.col("gap_medio_recarga")	Cliente está atrasando além do normal?
flg_quebra_padrao	quando a recência > 1,5 * gap_medio_recarga	<pre>F.when(F.col("recencia_dias") > 1.5 * F.col("gap_medio_recarga"), 1).otherwise(0)</pre>	Apresenta risco de churn?
score_risco_recencia	quanto menor, melhor	0: recência_dias <=7, 1:<=15, 2:<=30, 3:outros casos	Cliente com perfil ativo, inativo segundo recarga?
qtd_rec_plano_541200	quantidade de recargas do plano 541200	count(F.when(F.col("PLANO_TARIFACAO") == "541200", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_rec_plano_668900	quantidade de recargas do plano 668900	count(F.when(F.col("PLANO_TARIFACAO") == "668900", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_rec_plano_599100	quantidade de recargas do plano 599100	count(F.when(F.col("PLANO_TARIFACAO") == "599100", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_rec_plano_607690	quantidade de recargas do plano 607690	count(F.when(F.col("PLANO_TARIFACAO") == "607690", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_rec_plano_999999	quantidade de recargas do plano 999999	count(F.when(F.col("PLANO_TARIFACAO") == "999999", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_rec_plano_369889	quantidade de recargas do plano 369889	count(F.when(F.col("PLANO_TARIFACAO") == "369889", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_rec_plano_393401	quantidade de recargas do plano 393401	count(F.when(F.col("PLANO_TARIFACAO") == "393401", 1).otherwise(0))	Existe concentração em algum plano ?
qtd_tipo_insercao	quantidade distinta de tipos de inserção que cliente faz (cartão, zin, adicional, bônus)	countDistinct("DW_TIPO_INSERCAO")	Cliente faz apenas 1 ou mais tipos de inserção de recarga?
qtd_forma_pgto_na	quantidade de pagamentos não se aplica	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "-1", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_nd	quantidade de pagamentos não determinado	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "-2", 1))	Qual a forma de pagamento que o cliente prefere utilizar?

qtd_forma_pgto_ni	quantidade de pagamentos não informado	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "-3", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_cp	quantidade de pagamentos de crédito prepago	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "cp", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_dd	quantidade de pagamentos de débito direto	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "dd", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_mp	quantidade de pagamentos manuais	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "mp", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_pb	quantidade de pagamentos de arrecadação bancária	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "pb", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_ca	quantidade de pagamentos online	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "ca", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
qtd_forma_pgto_pa	quantidade de pagamentos feitos por acordo	count(F.when(F.col("DW_FORMA_PAGAMENTO") == "pa", 1))	Qual a forma de pagamento que o cliente prefere utilizar?
perfil_emergencial	recência em dias <= 7 e flg_uso_sos=1	(F.col("recencia_dias") <= 7) & (F.col("flg_uso_sos") == 1)	Recarrega só no sufoco? Recência x SOS
perfil_incentivado	recência em dias > 30 e fx_dependencia_bonús de "03_Media" ou "04_Alta"	(F.col("recencia_dias") > 30) & (F.col("fx_dependencia_bonus").isin("03_Media", "04_Alta"))	Precisa de incentivo? Recência x bônus
qtd_recarga_adicional_controle	Quantidade de recarga adicional Claro Controle	F.when(F.col("DW_TIPO_RECARGA") == 2, 1).otherwise(0) df_feat = (df_recargas .groupBy("NUM_CPF", "SAFRA_RECARGA") .agg(F.sum("flg_recarga_adicional_controle").alias("qtd_recarga_adicional_controle"), F.count("").alias("qtd_rec_total")))	Quantidade de recargas adicionais
flg_uso_recarga_adicional_controle	Cliente fez (1) ou não (0) recarga adicional no Claro controle	F.when(F.col("qtd_recarga_adicional_controle") > 0, 1).otherwise(0)	Cliente fez ao menos uma recarga adicional?
pct_recarga_adicional_controle	Intensidade da recarga adicional do claro controle no total de recargas do cliente	F.when(F.col("qtd_rec_total") > 0, F.col("qtd_recarga_adicional_controle") / F.col("qtd_rec_total")) .otherwise(0.0)	Intensidade do uso de adicional
qtd_rec_promocao	Sensibilidade a incentivo	df_rec = df_rec.withColumn("canal_macro", F.when(F.col("COD_CANAL_AQUISICAO").isin(-2, -3), "NAO_INFORMADO")) .when(F.lower(F.col("DSC_CANAL_AQUISICAO")).rlike("ap site web digital"), "DIGITAL")) .when(F.lower(F.col("DSC_CANAL_AQUISICAO")).rlike("loja pdv varejo banca"), "VAREJO")) .when(F.lower(F.col("DSC_CANAL_AQUISICAO")).rlike("parceiro convenio terceiro"), "PARCEIRO")) .when(F.lower(F.col("DSC_CANAL_AQUISICAO")).rlike("promocao acao campanha"), "PROMOCAO")) .otherwise("OUTRO"))	Qual sensível é o cliente a incentivos?

		<pre> "PROMOCAO") .otherwise("OUTROS")) df_feat_canal = (df_rec .groupby("NUM_CPF", "SAFRA_RECARGA") .agg(F.count("").alias("qtd_rec_total"), F.sum(F.when(F.col("canal_macro") == "DIGITAL", 1).otherwise(0)) .alias("qtd_rec_digital"), F.sum(F.when(F.col("canal_macro") == "VAREJO", 1).otherwise(0)) .alias("qtd_rec_varejo"), F.sum(F.when(F.col("canal_macro") == "PROMOCAO", 1).otherwise(0)) .alias("qtd_rec_promocao"), F.countDistinct("canal_macro").alias("qtd_canais_distintos"))) df_feat_canal = (df_feat_canal .withColumn("pct_rec_digital", F.col("qtd_rec_digital") / F.col("qtd_rec_total")) .withColumn("pct_rec_varejo", F.col("qtd_rec_varejo") / F.col("qtd_rec_total")) .withColumn("flg_canal_diversificado", F.when(F.col("qtd_canais_distintos") > 1, 1).otherwise(0))) </pre>	
qtd_canais_distintos	Flexibilidade de comportamento		Qual flexível é o cliente na aquisição das recargas?
pct_rec_digital	Proxy de maturidade digital	)	Qual a maturidade do cliente na aquisição da recarga em canais digitais?
pct_rec_varejo	Dependência de canal físico	)	Qual a dependência do cliente na aquisição da recarga em canais digitais?
flg_canal_diversificado	Resiliência / engajamento		Cliente adquire a recarga em mais de um canal?
qtd_eventos	quantidade de recargas nas plataformas por cliente e safra	F.count("").alias("qtd_eventos")	Qual intensidade de uso por cliente e safra?
qtd_pre_pago	quantidade de recargas nas plataformas pré-pago	<pre> F.when(F.col("COD_PLATAFORMA_ATU").startswith("PRE"), 1).otherwise(0) F.sum("flg_pre_pago").alias("qtd_pre_pago") </pre>	qual a intensidade absoluta de uso de cada perfil?
qtd_flex	quantidade de recargas nas plataformas flex	<pre> F.when(F.col("COD_PLATAFORMA_ATU").isin("FLEXD", "AUTOC"), 1).otherwise(0) F.sum("flg_flex").alias("qtd_flex") </pre>	qual a intensidade absoluta de uso de cada perfil?
qtd_autocontrole	quantidade de recargas nas plataformas de autocontrole	<pre> F.when(F.col("COD_PLATAFORMA_ATU") == "AUTOC", 1).otherwise(0) F.sum("flg_autocontrole").alias("qtd_autocontrole") </pre>	qual a intensidade absoluta de uso de cada perfil?
qtd_digital	quantidade de recargas nas plataformas digitais	<pre> F.when(F.col("COD_PLATAFORMA_ATU").isin("FLEXD", "AUTOC", "MVNOD"), 1).otherwise(0) F.sum("flg_digital").alias("qtd_digital") </pre>	qual a intensidade absoluta de uso de cada perfil?
flg_bloqueado	flag para sinal de possível churn, inadimplência ou ruptura recente do consumo	<pre> F.when(F.col("COD_PLATAFORMA_ATU").isin("PREBL", "POSBL", "CTLBL"), 1) </pre>	Cliente é de alto risco?

flg_restricao_credito	flag para sinal de problema financeiro ativo, perfil crítico para crédito e oferta	F.when(F.col("COD_PLATAFORMA_ATU").isin("POSBC", "POSCW", "POSRI"), 1)	Cliente com problema financeiro ativo?
flg_ao_humano	flag para sinalizar linha não comportamental	F.when(F.col("COD_PLATAFORMA_ATU").isin("M2MS", "SGIOT"), 1)	Dados sem sinal comportamental?
flg_tecnico	flag para sinalizar casos sem sinal preditivo	F.when(F.col("COD_PLATAFORMA_ATU").isin("-1", "-2", "-3"), 1)	Dados sem contribuição preditiva?
qtd_plataformas_distintas	mede estabilidade de comportamento	F.countDistinct("COD_PLATAFORMA_ATU")	Cliente tem perfil consistente ou mais volátil, oportunista?
pct_pre_pago	Quanto o cliente é estruturalmente pré-pago	F.col("qtd_pre_pago") / F.col("qtd_eventos")	Cliente concentrado em recarga pré-paga?
pct_flex	mede grau de elasticidade e modernização do perfil do cliente	F.col("qtd_flex") / F.col("qtd_eventos")	Cliente concentrado em recarga flex?
pct_autocontrole	mede recorrência, previsibilidade e fidelização	F.col("qtd_autocontrole") / F.col("qtd_eventos")	Cliente concentrado em recarga autocontrole?
pct_digital	Mede maturidade digital e propensão a canais digitais	F.col("qtd_digital") / F.col("qtd_eventos")	Cliente concentrado em recarga digital?
pct_flex_lag	mede grau de elasticidade e modernização do perfil do cliente da safra anterior	F.lag("pct_flex").over(w)	qual histórico de concentração em recarga flex do cliente?
flg_migracao_plataforma	flag criada para sinal de mudança de perfil do cliente	F.when((F.col("pct_flex_lag").isNotNull()) & (F.col("pct_flex") != F.col("pct_flex_lag")),).otherwise(0)	1 Cliente instável ou em transição de ciclo de vida?
flg_upgrade_flex	flag criada para sinal de evolução positiva: maior engajamento e potencial de valor.	F.when((F.col("pct_flex_lag") < 0.5) & (F.col("pct_flex") >= 0.5),).otherwise(0)	1 Clientes com mais potencial e engajamento?
flg_downgrade_flex	flag criada para sinal precoce de churn ou perda de capacidade de pagamento	F.when((F.col("pct_flex_lag") >= 0.5) & (F.col("pct_flex") < 0.5),).otherwise(0)	1 Clientes estão desacelerando?
flg_excluir_modelo	Flag técnica para retirar registros não elegíveis ao modelo comportamental	F.when((F.col("flg_ao_humano") == 1) (F.col("flg_tecnico") == 1),).otherwise(0)	1 Clientes em plataformas elegíveis para o estudo? (plataformas que envolvem linha não comportamental ou sem sinal preditivo não deve entrar no modelo)
flg_linha_ativa	Indica se a linha esteve ativa ou temporariamente suspensa	F.when(F.col("COD_STATUS_PLATAFORMA").isin("A", "ST"), 1).otherwise(0)	Cliente operacional e elegível ao consumo e recarga?
flg_expirado_recente	Indica expiração recente de crédito/linha	F.when(F.col("COD_STATUS_PLATAFORMA") == "ZB1", 1).otherwise(0)	Cliente alto propenso de churn, apresenta oportunidade de reativação?
flg_churn_profundo	Indica desconexão, inatividade estrutural ou perda definitiva	F.when(F.col("COD_STATUS_PLATAFORMA").isin("ZB2", "C"), 1).otherwise(0)	Cliente é desconexo, com baixa resposta a estímulos?
flg_status_ruido	Status técnicos, inconsistentes ou não informados	F.when(F.col("COD_STATUS_PLATAFORMA") .isin("-3", "U", "F", "V", "S", "AT"),).otherwise(0)	1 Cliente apresenta baixa confiabilidade comportamental?

pct_linha_ativa	Proporção do tempo/registros em que esteve ativo	F.col("qtd_linha_ativa") / F.col("qtd_eventos_status")	Cliente com linha saudável e engajado?
pct_expirado_recente	Proporção do tempo em expiração recente	F.col("qtd_expirado_recente") / F.col("qtd_eventos_status")	Cliente arriscado?
qtd_status_distintos	Número de status diferentes no período	F.countDistinct("COD_STATUS_PLATAFORMA")	Cliente estável?
flg_cliente_elegivel	Cliente ativo e sem churn profundo	F.when((F.col("pct_linha_ativa") > 0.5) & (F.col("qtd_churn_profundo") == 0), 1).otherwise(0)	Cliente sem persistência de perda e churn?
QTD_RECARGAS_DIGITAL	Quantidade de recargas em instituições digitais	F.sum("FLG_RECARGA_DIGITAL").alias("QTD_RECARGAS_DIGITAL")	Cliente recarrega muito em instituição digital? cliente mais autônomo?
QTD_RECARGAS_BANCO	Quantidade de recargas em instituições bancárias	F.sum("FLG_RECARGA_BANCO").alias("QTD_RECARGAS_BANCO")	Cliente recarrega muito em instituição bancária? Cliente com perfil financeiro mais estruturado?
QTD_RECARGAS_VAREJO	Quantidade de recargas em instituições de varejo	F.sum("FLG_RECARGA_VAREJO").alias("QTD_RECARGAS_VAREJO")	Cliente recarrega muito em instituição de varejo? Cliente menos digital, tem mais dependência física?
QTD_RECARGAS_TELECOM	Quantidade de recargas em instituições de telecomunicações	F.sum("FLG_RECARGA_TELECOM").alias("QTD_RECARGAS_TELECOM")	Cliente recarrega muito em instituição de telecom? Cliente mais engajado com operadoras?
FLG_RECARGA_BANCO	indica se faz recarga em instituições bancárias	F.when(F.col("CATEGORIA_TIPO_INSTITUICAO") == "BANCO", 1).otherwise(0)	Cliente faz recarga em instituições bancárias?
FLG_RECARGA_DIGITAL	indica se faz recarga em instituições digitais	F.when(F.col("CATEGORIA_TIPO_INSTITUICAO") == "DIGITAL_WALLET", 1).otherwise(0)	Cliente faz recarga em instituições digitais?
FLG_RECARGA_VAREJO	indica se faz recarga em instituições de varejo	F.when(F.col("CATEGORIA_TIPO_INSTITUICAO") == "VAREJO_FISICO", 1).otherwise(0)	Cliente faz recarga em instituições de varejo?
FLG_RECARGA_TELECOM	indica se faz recarga em instituições de telecom	F.when(F.col("CATEGORIA_TIPO_INSTITUICAO") == "TELECOM_CANAL", 1).otherwise(0)	Cliente faz recarga em instituições de telecomunicações?
FLG_RECARGA_TECNICA	indica se faz recarga em instituições de telecom	F.when(F.col("CATEGORIA_TIPO_INSTITUICAO") == "TECNICO", 1).otherwise(0)	Cliente faz recarga em instituições bancárias?
PCT_RECARGA_DIGITAL	percentual de recargas em instituições digitais	F.col("QTD_RECARGAS_DIGITAL") / F.col("QTD_RECARGAS_TOTAL")	qual a preferencia de instituição para recarregar?
PCT_RECARGA_BANCO	percentual de recargas em instituições bancárias	F.col("QTD_RECARGAS_BANCO") / F.col("QTD_RECARGAS_TOTAL")	qual a preferencia de instituição para recarregar?
PCT_RECARGA_VAREJO	percentual de recargas em instituições de varejo	F.col("QTD_RECARGAS_VAREJO") / F.col("QTD_RECARGAS_TOTAL")	qual a preferencia de instituição para recarregar?
PCT_RECARGA_TELECOM	percentual de recargas em instituições de telecom	F.col("QTD_RECARGAS_TELECOM") / F.col("QTD_RECARGAS_TOTAL")	qual a preferencia de instituição para recarregar?
INSTITUICAO_DOMINANTE_RECARGA	Tipo de instituição em que o cliente fez mais recarga	F.when(F.col("QTD_RECARGAS_DIGITAL") >= F.greatest("QTD_RECARGAS_BANCO", "QTD_RECARGAS_VAREJO", "QTD_RECARGAS_TELECOM"), 1).otherwise(0)	Qual tipo de instituição é a preferida do cliente?

		<pre> "DIGITAL").when(F.col("QTD_RECARGAS_BANCO") >= F.greatest("QTD_RECARGAS_VAREJO", "QTD_RECARGAS_TELECOM"), "BANCO").when(F.col("QTD_RECARGAS_VAREJO") >= F.col("QTD_RECARGAS_TELECOM"), "VAREJO").otherwise("TELECOM") </pre>	
GRUPO_CARTAO_DOMINANTE	Indica o grupo mais utilizado	F.sum("qtd_recargas_grupo")	qual grupo é o preferido?
PCT_GRUPO_CARTAO_DOMINANTE	percentual do grupo mais utilizado dentre os grupos que o cliente utilizou	F.col("qtd_recargas_grupo") / F.col("qtd_recargas_total")	Quão forte é o padrão dominante
QTD_GRUPOS_CARTAO_DISTINTOS	quantidade de grupos de cartão que o cliente utiliza	F.countDistinct("COD_GRUPO_CARTAO")	Quão variado é o comportamento no uso?
DSC_GRUPO_CARTAO_DOMINANTE	Categoria semântica do tipo de cartão/recarga mais utilizada pelo CPF na safra (ex.: Recarga Online, Ativação Promo, Cartão Físico, Pacote, Chip)	<pre> w = Window.partitionBy("NUM_CPF", "SAFRA_RECARGA").orderBy(F.desc("qtd_rec")) df_dom = (df_cat .withColumn("rn", F.row_number().over(w)) .filter(F.col("rn") == 1) .select("NUM_CPF", "SAFRA_RECARGA", F.col("CAT_DSC_GRUPO_CARTAO")) </pre>	Qual o grupo cartão preferido do cliente?
PCT_DSC_GRUPO_CARTAO_DOMINANTE	Percentual das recargas concentradas na categoria dominante	F.col("qtd_rec") / F.col("qtd_rec_total")	Cliente com comportamento consolidado ou oportunista/multicanal?
QTD_DSC_GRUPO_CARTAO_DISTINTOS	Quantidade de categorias diferentes de cartão/recarga usadas pelo cliente	F.countDistinct("CAT_DSC_GRUPO_CARTAO")	Clientes mais exploratórios e menos previsíveis?
FLG_RECARGA_ONLINE	Indica se o cliente realizou ao menos uma recarga online	<pre> F.sum("qtd_rec") .fillna(0) .select("NUM_CPF", "SAFRA_RECARGA", (F.col("RECARGA_ONLINE") > 0).cast("int").alias("FLG_RECARGA_ONLINE"), </pre>	Cliente mais digitalizado?
FLG_ATIVACAO_PROMO	Indica uso de recargas associadas a promoções/ativação	<pre> (F.col("ATIVACAO_PROMO") > 0).cast("int").alias("FLG_ATIVACAO_PROMO"), </pre>	Cliente mais dependente de incentivos?
FLG_CARTAO_FISICO	Indica uso de cartão físico	<pre> (F.col("CARTAO_FISICO") > 0).cast("int").alias("FLG_CARTAO_FISICO"), </pre>	Cliente menos engajado digitalmente?
FLG_PACOTE_SERVICO	Indica compra de pacotes (voz, SMS, dados)	<pre> (F.col("PACOTE_SERVICO") > 0).cast("int").alias("FLG_PACOTE_SERVICO"), </pre>	Cliente com perfil planejador (consumo mais previsível)?
FLG_CHIP	Indica compra/uso de chip (ativação ou reposição)	<pre> (F.col("CHIP") > 0).cast("int").alias("FLG_CHIP") </pre>	Cliente recente na base (ativação ou reposição)?

8.1.5 Variáveis de Janela Temporal (28->140)

As variáveis de janela capturam intensidade e tendência de comportamento em diferentes horizontes temporais (1, 3, 6, 9 e 12 meses), permitindo análises dinâmicas e redução de ruído pontual.

Criamos ao todo 635 variáveis únicas que são replicadas por período totalizando 3.175 variáveis finais, que somadas as 114 do book, resultam no book de recargas total de 3.289 variáveis.

Para utilização do modelo base e por questões de processamento seguiremos com as 114 variáveis do book mais 28 variáveis únicas de janelamento (140 variáveis ao todo), resultando no book final de 254 variáveis. Caso haja necessidade após rodagem do modelo base, com mais disponibilidade de recursos, é possível incluir as 607 variáveis únicas criadas.

Variável	Definição	Fórmula / Regra	Pergunta que Responde
mean_pct_rec_sos_u{months}m	Média percentual de recargas SOS	F.avg("pct_rec_sos").over(w).alias(f"mean_pct_rec_sos_u{months}m")	Qual a intensidade média do uso de recargas SOS nos últimos {months} meses?
mean_pct_rec_com_bonuss_u{months}m	Média percentual de recargas com bônus	F.avg("pct_rec_com_bonus").over(w).alias(f"mean_pct_rec_com_bonus_u{months}m")	Qual a proporção média de recargas que recebem bônus no período?
mean_gap_medio_recarga_u{months}m	Média do intervalo entre recargas (dias)	F.avg("gap_medio_recarga").over(w).alias(f"mean_gap_medio_recarga_u{months}m")	Com que frequência, em média, o cliente recarrega?
mean_recencia_dias_u{months}m	Média da recência em dias	F.avg("recencia_dias").over(w).alias(f"mean_recencia_dias_u{months}m")	Há quanto tempo, em média, o cliente realizou a última recarga?
qtd_recargas_u{months}m	Contagem de recargas	F.count("qtd_recargas").over(w).alias(f"qtd_recargas_u{months}m")	Quantas recargas o cliente fez no período?
qtd_rec_sos_u{months}m	Contagem de recargas SOS	F.count("qtd_rec_sos").over(w).alias(f"qtd_rec_sos_u{months}m")	Quantas recargas SOS foram feitas no período?
qtd_canais_distintos_u{months}m	Número de canais distintos de recarga	F.count("qtd_canais_distintos").over(w).alias(f"qtd_canais_distintos_u{months}m")	Em quantos canais diferentes o cliente recarregou?
qtd_eventos_u{months}m	Contagem de eventos relacionados	F.count("qtd_eventos").over(w).alias(f"qtd_eventos_u{months}m")	Quanto eventos (transações/ações) relacionados a recarga ocorreram?
std_vlr_medio_recarga_u{months}m	Desvio padrão do valor médio de recarga	F.stddev("vlr_medio_recarga").over(w).alias(f"std_vlr_medio_recarga_u{months}m")	Qual a variabilidade no valor médio das recargas?

std_pct_rec_com_bonus_u{months}m	Desvio padrão do % de recargas com bônus	F.stddev("pct_rec_com_bonus").over(w).alias(f"std_pct_rec_com_bonus_u{months}m")	Há variação na proporção de recargas com bônus entre meses?
std_gap_medio_recarga_u{months}m	Desvio padrão do gap médio entre recargas	F.stddev("gap_medio_recarga").over(w).alias(f"std_gap_medio_recarga_u{months}m")	A frequência de recarga é consistente ou variável?
std_recencia_dias_u{months}m	Desvio padrão da recência (dias)	F.stddev("recencia_dias").over(w).alias(f"std_recencia_dias_u{months}m")	Variedade no tempo desde a última recarga entre períodos?
sum_qtd_recargas_u{months}m	Soma total de recargas	F.sum("qtd_recargas").over(w).alias(f"sum_qtd_recargas_u{months}m")	Qual o total de recargas realizadas no período?
sum_vlr_recarga_u{months}m	Soma do valor total recarregado	F.sum("vlr_total_recarga").over(w).alias(f"sum_vlr_recarga_u{months}m")	Quanto foi recarregado no total no período?
sum_vlr_total_bonus_u{months}m	Soma do valor total em bônus	F.sum("vlr_total_bonus").over(w).alias(f"sum_vlr_total_bonus_u{months}m")	Quanto em bônus foi concedido/recebido no período?
sum_vlr_total_real_u{months}m	Soma do valor real (líquido) recarregado	F.sum("vlr_total_real").over(w).alias(f"sum_vlr_total_real_u{months}m")	Qual o valor efetivo (sem bônus) recarregado no período?
sum_qtd_rec_sos_u{months}m	Soma de recargas SOS	F.sum("qtd_rec_sos").over(w).alias(f"sum_qtd_rec_sos_u{months}m")	Quantas recargas SOS no total no período?
sum_qtd_rec_com_bonus_u{months}m	Soma de recargas com bônus	F.sum("qtd_rec_com_bonus").over(w).alias(f"sum_qtd_rec_com_bonus_u{months}m")	Quantas recargas com bônus no total no período?
sum_qtd_eventos_u{months}m	Soma de eventos	F.sum("qtd_eventos").over(w).alias(f"sum_qtd_eventos_u{months}m")	Quanto eventos relacionados ocorreram no total?
qtd_meses_uso_sos_u{months}m	Meses com uso de SOS	F.sum("fig_uso_sos").over(w).alias(f"qtd_meses_uso_sos_u{months}m")	Em quantos meses o cliente utilizou recarga SOS?
qtd_meses_quebra_padrao_u{months}m	Meses com quebra de padrão	F.sum("fig_quebra_padrao").over(w).alias(f"qtd_meses_quebra_padrao_u{months}m")	Em quantos meses o comportamento do cliente quebrou o padrão esperado?
qtd_meses_uso_recarga_adicional_controle_u{months}m	Meses com uso de recarga adicional de controle	F.sum("fig_uso_recarga_adicional_controle").over(w).alias(f"qtd_meses_uso_recarga_adicional_controle_u{months}m")	Em quantos meses o cliente usou recarga adicional por controle?
qtd_meses_perfil_emergencial_u{months}m	Meses com perfil emergencial	F.sum("perfil_emergencial").over(w).alias(f"qtd_meses_perfil_emergencial_u{months}m")	Em quantos meses o cliente apresentou perfil emergencial?
qtd_meses_perfil_incentivado_u{months}m	Meses com perfil incentivado	F.sum("perfil_incentivado").over(w).alias(f"qtd_meses_perfil_incentivado_u{months}m")	Em quantos meses o cliente apresentou perfil incentivado?

flg_uso_sos_u{months}m	Indicador de uso SOS no período	F.max("flg_uso_sos").over(w).alias(f"flg_uso_sos_u{months}m")	O cliente usou SOS ao menos uma vez no período?
fx_dependencia_bonus_u{months}m	Indicador de dependência a bônus (quebra padrão)	F.max("flg_quebra_padrao").over(w).alias(f"fx_dependencia_bonus_u{months}m")	O cliente mostrou dependência de bônus/quebra de padrão no período?
perfil_emergencial_u{months}m	Indicador de perfil emergencial no período	F.max("perfil_emergencial").over(w).alias(f"perfil_emergencial_u{months}m")	O cliente teve comportamento de perfil emergencial em algum mês?
perfil_incentivado_u{months}m	Indicador de perfil incentivado no período	F.max("perfil_incentivado").over(w).alias(f"perfil_incentivado_u{months}m")	O cliente teve comportamento de perfil incentivado em algum mês?

7.1.6 Observações Finais

Esse book permite entender *quando*, *quanto*, *como*, *onde* e *por que* o cliente recarrega — e, principalmente, *quem vai continuar recarregando e quem está prestes a parar*.

Dimensão Analítica	Perguntas que podem ser respondidas	Variáveis que respondem o bloco
Tempo & Ciclo de Vida (8)	Quando foi a primeira/última recarga? O cliente está ativo? Está atrasando além do padrão?	SAFRA_RECARGA, dt_primeira_recarga, dt_ultima_recarga, recencia_dias, fx_recencia, desvio_recencia, flg_quebra_padrao, score_risco_recencia
Frequência & Intensidade (5)	Com que frequência recarrega? Consumo recorrente ou esporádico?	qtd_recargas, gap_medio_recarga, gap_std_recarga, qtd_eventos, qtd_telefones
Valor & Monetização (6)	Quanto o cliente consome? Ticket alto ou baixo?	vlr_total_recarga, vlr_medio_recarga, vlr_max_recarga, vlr_min_recarga, vlr_total_real, vlr_medio_real
Horário de Consumo (5)	Em qual horário recarrega? É consumo planejado ou emergencial?	qtd_rec_madrugada, qtd_rec_manha, qtd_rec_tarde, qtd_rec_noite, fx_hora_dominante
SOS / Emergencial (5)	Usa SOS? Uso pontual ou recorrente?	qtd_rec_sos, vlr_medio_rec_sos, flg_uso_sos, pct_rec_sos, perfil_emergencial
Bônus & Incentivos (7)	Depende de bônus? Responde a promoções?	qtd_rec_com_bonus, vlr_rec_com_bonus, vlr_total_bonus, vlr_medio_bonus, pct_rec_com_bonus, fx_dependencia_bonus, perfil_incentivado
Canal de Recarga (8)	Qual canal prefere? É digital ou físico?	canal_principal, qtd_rec_digital, qtd_rec_varejo, qtd_rec_promocao, pct_rec_digital, pct_rec_varejo, qtd_canais_distintos, flg_canal_diversificado
Forma de Pagamento (9)	Como o cliente paga? Perfil financeiro estruturado?	qtd_forma_pgto_na, qtd_forma_pgto_nd, qtd_forma_pgto_ni, qtd_forma_pgto_cp, qtd_forma_pgto_dd, qtd_forma_pgto_mp, qtd_forma_pgto_pb, qtd_forma_pgto_ca, qtd_forma_pgto_pa

Dimensão Analítica	Perguntas que podem ser respondidas	Variáveis que respondem o bloco
Planos & Tarifação (7)	Existe concentração em plano? Mudança de perfil?	qtd_rec_plano_541200, qtd_rec_plano_668900, qtd_rec_plano_599100, qtd_rec_plano_607690, qtd_rec_plano_999999, qtd_rec_plano_369889, qtd_rec_plano_393401
Recarga Adicional / Controle (5)	Usa recarga adicional? Qual intensidade?	qtd_recarga_adicional_controle, flg_uso_recarga_adicional_controle, pct_recarga_adicional_controle, flg_bloqueado, flg_restricao_credito
Plataforma & Perfil (8)	Pré, flex ou autocontrole? Perfil está evoluindo?	qtd_pre_pago, qtd_flex, qtd_autocontrole, qtd_digital, pct_pre_pago, pct_flex, pct_autocontrole, pct_digital
Migração & Transição (4)	Cliente migrou de perfil? Upgrade ou downgrade?	pct_flex_lag, flg_migracao_plataforma, flg_upgrade_flex, flg_downgrade_flex
Estabilidade Comportamental (2)	Cliente estável ou volátil?	qtd_plataformas_distintas, qtd_status_distintos
Status da Linha (7)	Linha ativa? Churn profundo?	flg_linha_ativa, flg_expirado_recente, flg_churn_profundo, flg_status_ruido, pct_linha_ativa, pct_expirado_recente, flg_cliente_elegivel
Instituição de Recarga (14)	Onde prefere recarregar? Perfil financeiro ou físico?	QTD_RECARGAS_DIGITAL, QTD_RECARGAS_BANCO, QTD_RECARGAS_VAREJO, QTD_RECARGAS_TELECOM, PCT_RECARGA_DIGITAL, PCT_RECARGA_BANCO, PCT_RECARGA_VAREJO, PCT_RECARGA_TELECOM, INSTITUICAO_DOMINANTE_RECARGA, FLG_RECARGA_BANCO, FLG_RECARGA_DIGITAL, FLG_RECARGA_VAREJO, FLG_RECARGA_TELECOM, FLG_RECARGA_TECNICA
Grupo / Tipo de Cartão (6)	Tipo de recarga preferido? Padrão concentrado?	GRUPO_CARTAO_DOMINANTE, PCT_GRUPO_CARTAO_DOMINANTE, QTD_GRUPOS_CARTAO_DISTINTOS, DSC_GRUPO_CARTAO_DOMINANTE, PCT_DSC_GRUPO_CARTAO_DOMINANTE, QTD_DSC_GRUPO_CARTAO_DISTINTOS
Digitalização & Produto (5)	Cliente é digital? Compra pacote, chip ou promo?	FLG_RECARGA_ONLINE, FLG_ATIVACAO_PROMO, FLG_CARTAO_FISICO, FLG_PACOTE_SERVICO, FLG_CHIP
Elegibilidade Técnica (3)	Pode entrar no modelo?	flg_nao_humano, flg_tecnico, flg_excluir_modelo
Tipo de inserção (1)	Cliente faz inserção de apenas um jeito?	qtd_tipo_insercao

Variáveis de janelamento:

Dimensão Analítica	Perguntas que podem ser respondidas	Variáveis que respondem o bloco
Intensidade / Proporções (médias)[2]	Qual a intensidade/proporção média de certos comportamentos no período?	mean_pct_rec_sos_u{months}m, mean_pct_rec_com_bonus_u{months}m

Dimensão Analítica	Perguntas que podem ser respondidas	Variáveis que respondem o bloco
Frequência / Tempo (médias) [2]	Com que frequência/quanto tempo decorre entre recargas e desde a última recarga?	mean_gap_medio_recarga_u{months}m, mean_recencia_dias_u{months}m
Contagens / Volume de eventos [4]	Quantos eventos/recargas ocorreram no período?	qtd_recargas_u{months}m, qtd_rec_sos_u{months}m, qtd_canais_distintos_u{months}m, qtd_eventos_u{months}m
Somas / Valores monetários [7]	Qual o total em quantidade/valor recarregado e em bônus no período?	sum_qtd_recargas_u{months}m, sum_vlr_recarga_u{months}m, sum_vlr_total_bonus_u{months}m, sum_vlr_total_real_u{months}m, sum_qtd_rec_sos_u{months}m, sum_qtd_rec_com_bonus_u{months}m, sum_qtd_eventos_u{months}m
Variabilidade (desvios padrão) [4]	Quão variável é o comportamento/valores ao longo do período?	std_vlr_medio_recarga_u{months}m, std_pct_rec_com_bonus_u{months}m, std_gap_medio_recarga_u{months}m, std_recencia_dias_u{months}m
Meses com características / Soma de flags [5]	Em quantos meses o cliente apresentou determinado comportamento?	qtd_meses_uso_sos_u{months}m, qtd_meses_quebra_padrao_u{months}m, qtd_meses_uso_recarga_adicional_controle_u{months}m, qtd_meses_perfil_emergencial_u{months}m, qtd_meses_perfil_incentivado_u{months}m
Indicadores binários / Flags agregados [4]	O cliente apresentou determinado comportamento ao menos uma vez no período?	flg_uso_sos_u{months}m, fx_dependencia_bonus_u{months}m, perfil_emergencial_u{months}m, perfil_incentivado_u{months}m

7.1.7 Anexos

Explicação básica dos códigos de tecnologia (COD_TECNOLOGIA_DW):

Tecnologia	Geração	Uso principal	Leitura analítica
TDMA	2G	Voz básica	Legado / risco
GSM	2G	Voz + SMS	Baixo consumo

3G	3G	Internet básica	Intermediário
4G	4G	Dados intensivos	Alto engajamento
5G	5G	Dados premium	Cliente de valor

Explicação básica dos códigos de plataforma de atuação (COD_PLATAFORMA_ATU):

A variável de plataforma foi transformada em indicadores de segmento, engajamento digital, recorrência (autocontrole), risco e migração entre plataformas. O código original não foi utilizado diretamente devido à alta concentração e baixa variabilidade informacional.

Código	Categoria	Significado Funcional	Leitura Analítica / Uso
PREPG	Pré-pago	Pré-pago tradicional (legacy)	Cliente antigo, baixo ticket, menor engajamento
PRECT	Pré-pago	Pré-pago convergente (intermediário)	Engajamento médio, boa resposta a incentivos
PRECN	Pré-pago	Pré-pago convergente (novo)	Cliente ativo, maior frequência de recarga
PREBL	Pré-pago	Pré-pago bloqueado	Forte sinal de churn/inatividade
PRERO	Pré-pago	Pré-pago em roaming	Exceção, comportamento atípico
POSTL	Pós-pago	Pós-pago tradicional (legacy)	Perfil antigo, consumo estável
POSPG	Pós-pago	Pós-pago padrão	Base regular
POSDT	Pós-pago	Pós-pago digital	Cliente mais engajado e digital
POSCM	Pós-pago	Pós-pago corporativo	Alto valor, comportamento distinto
POSCP	Pós-pago	Pós-pago controle pessoal	Intermediário entre pré e pós
POSFX	Pós-pago	Pós-pago franquia fixa	Consumo previsível
POSBL	Pós-pago	Pós-pago bloqueado	Risco financeiro
POSBC	Pós-pago	Pós-pago bloqueado por cobrança	Forte sinal de inadimplência
POSCW	Pós-pago	Pós-pago com cobrança em aberto	Risco elevado
POSRI	Pós-pago	Pós-pago com restrição interna	Compliance / inadimplência
CTLBL	Controle	Controle bloqueado	Alto risco
CTLFC	Controle	Controle com franquia controlada	Perfil estável
FLEXD	Flex	Plano flex digital	Cliente elástico a preço
AUTOC	Flex	Autocontrole / autorrecarga	Forte indicador de recorrência
MVNO	MVNO	Operadora virtual	Regra de negócio distinta

MVNO D	MVNO	Operadora virtual digital	Cliente altamente digital
M2MS	IoT	M2M / IoT simples	Excluir de modelos comportamentais
SGIOT	IoT	IoT avançado	Não humano, excluir
VROAM	Especial	Voz em roaming	Uso eventual
VRINT	Especial	Voz internacional	Cliente específico
-1	Técnico	Não se aplica	Tratar como erro
-2	Técnico	Não definido	Ruído cadastral
-3	Técnico	Não informado	Ruído

Explicação básica da natureza das recargas (COD_TIPO_CREDITO):

Código	Descrição	Significado Funcional	Leitura Analítica
PE	Online	Recarga feita por canal digital (app, site, internet banking)	Cliente digital, maior propensão à recorrência
AU	Autocontrole	Crédito inserido automaticamente (ex: recarga programada)	Forte sinal de hábito e estabilidade
BO	Bônus	Crédito promocional concedido pela operadora	Dependência de incentivo, não representa esforço
CF	Cartão Físico	Recarga via cartão físico (raspadinha)	Perfil tradicional, menor digitalização
CV	PIN Eletrônico	Recarga via código eletrônico (PIN)	Intermediário entre físico e digital
TE	Transferência Eletrônica	Crédito transferido entre linhas	Comportamento compartilhado / familiar
TF	TEF	Recarga via transferência eletrônica financeira (POS, varejo)	Canal físico estruturado
IO	loio	Crédito promocional específico / legado	Geralmente tratar como "Outros"

OU	Outros	Tipos não classificados	Ruído ou exceção
-1	NA	Não Aplicável	Tratar como nulo técnico
-2	ND	Não Determinado	Ruído cadastral
-3	NI	Não Informado	Ruído cadastral

Explicação básica códigos promocionais (COD_PROMOCAO):

COD_PROMOCAO	Nome resumido	Descrição funcional	Categoria analítica	Incentivo real?	Uso recomendado no modelo
317	Débito Automático	Incentivo financeiro para adesão ao débito automático	INCENTIVO_REAL	✓ Sim	Flag de fidelização
318	Recarga Turbinada	Bônus aplicado às recargas	INCENTIVO_REAL	✓ Sim	Sensibilidade a bônus
319	Ação Claro Visa	Bônus por parceria com cartão	INCENTIVO_REAL	✓ Sim	Afinidade com parcerias
322	Recarga Bonificada	Bônus para recargas de baixo valor	INCENTIVO_REAL	✓ Sim	Perfil baixo ticket
337	Créditos Adicionais	Bônus em conta dedicada	INCENTIVO_REAL	✓ Sim	Dependência de incentivo
368	Créditos Adicionais	Mesmo benefício (versão atualizada)	INCENTIVO_REAL	✓ Sim	Dependência de incentivo
378	Créditos Adicionais	Mesmo benefício (versão atualizada)	INCENTIVO_REAL	✓ Sim	Dependência de incentivo
320	Troca de Portfólio	Ajuste estrutural de produtos	ALTERACAO_REGRA	✗ Não	Ignorar
321	Alteração de Validade	Mudança de regra de validade	ALTERACAO_REGRA	✗ Não	Ignorar
367	Alteração de Validade	Mesmo ajuste (versão atualizada)	ALTERACAO_REGRA	✗ Não	Ignorar
377	Alteração de Validade	Mesmo ajuste (versão atualizada)	ALTERACAO_REGRA	✗ Não	Ignorar
327	Anatel 632	Adequação regulatória	ALTERACAO_REGRA	✗ Não	Ignorar
347	Histórico de Alterações	Log técnico de mudanças	HISTORICO_TECNICO	✗ Não	Excluir
369	Histórico de Alterações	Log técnico (versão atualizada)	HISTORICO_TECNICO	✗ Não	Excluir
379	Histórico de Alterações	Log técnico (versão atualizada)	HISTORICO_TECNICO	✗ Não	Excluir

Explicação básica do DW_TIPO_RECARGA:

As variáveis derivadas de DW_TIPO_RECARGA capturam o comportamento de consumo planejado (franquia) versus consumo adicional. Valores não informativos são desconsiderados, e o uso de recargas adicionais é tratado como proxy de pressão de consumo e possível risco comportamental.

Explicação básica do COD_CANAL_AQUISICAO:

O campo COD_CANAL_AQUISICAO apresenta alta cardinalidade e elevada taxa de não preenchimento. Para fins analíticos, os canais foram consolidados em macro-categorias com base em sua natureza operacional, permitindo a extração de indicadores robustos de preferência de canal, diversificação e maturidade digital do cliente.

Explicação básica do COD_STATUS_PLATAFORMA:

As variáveis de status de plataforma foram transformadas em indicadores de atividade, risco e ruído cadastral. O código original foi descartado devido à alta concentração no estado ativo, priorizando métricas proporcionais e flags de expiração recente.

Explicação básica do DW_INSTITUICAO:

As variáveis relacionadas à instituição de recarga foram construídas a partir de agregações comportamentais, evitando o uso direto de chaves cadastrais e capturando padrões de concentração, diversidade e dependência institucional.

Explicação básica do COD_GRUPO_CARTAO:

É um código compacto (2 caracteres) que identifica tecnicamente qual grupo de cartão, voucher ou produto foi aplicado na recarga dentro do WPP.

Explicação básica do DSC_GRUPO_CARTAO_WPP:

A variável DSC_GRUPO_CARTAO_WPP classifica o tipo de produto ou voucher associado à recarga, permitindo diferenciar recargas puras de ativações promocionais, pacotes e compras de chip com crédito. Para fins analíticos, categorias raras e não informativas são consolidadas, extraíndo-se indicadores de jornada, uso de promoção e compra de pacotes.

7.2 Atrasos (Versão Analítica e Executiva)

7.2.1 Visão Executiva

Este documento apresenta o Book de Variáveis de Atrasos, desenvolvido para caracterizar o comportamento histórico de inadimplência, regularidade de pagamento, severidade do atraso e maturidade do cliente, para explicar e prever padrões de recarga sob risco.

7.2.2 Evolução da Base de Dados

- Base original de atrasos: 31.611.316 registros, 50 colunas.
- Base score full: 3.590.459 CPFs distintos (6 safras).
- Safras analisadas (202410 a 202501): 2.462.481 CPFs válidos.
- Após cruzamento com atrasos: 23.242.810 registros e 1.719.990 CPFs.
- Após exclusão de safras OOT (202502, 202503, 202504): 16.644.398 registros e 1.240.975 CPFs.
- Safras finais de atrasos: out/23 a jan/25 (16 safras).
- Adotamos o campo DAT_REFERENCIA_ATRASO para criação da variável SAFRA_ATRASO pela consistência e completude dos dados, além do próprio nome indicando o propósito da variável.

7.2.3 Variáveis Brutas da Base (43)

As variáveis brutas foram avaliadas quanto à cardinalidade, preenchimento e relevância analítica. Campos com valor único, predominância extrema ou alta cardinalidade sem ganho analítico, além de variáveis técnicas, não serão incluídos no book.

Campos não incluídos [7]:

Identificadores técnicos [5]:

NUM_FATURA_HASH_ATRASO,
NUM_ENT_SEQ_FATURA_ATRASO,
NUM_BILL_SEQ_FAT_ATRASO,
NUM_SEQ_ACORDO_FAT_ATRASO,
DW_NUM_CLIENTE_ATRASO

Campos com missing [2]:

Com relação aos nulos das colunas temos que 2 colunas apresentam nulos acima de 99% e por isso não serão utilizadas:

DAT_CANCELAMENTO_FAT_ATRASO: 16.644.398 (100.0)

DAT_ALTERACAO_VCTO_FAT_ATRASO: 16.598.059 (99.72)

coluna	qtd_registros	qtd_nulos	qtd_distintos	pct_nulos	pct_distintos
DAT_CANCELAMENTO_FAT_ATRASO	16644398	16644398	0	100.0	0.0
DAT_ALTERACAO_VCTO_FAT_ATRASO	16644398	16598059	650	99.72	0.0
DAT_ORIGINAL_VCTO_FAT_ATRASO	16644398	734792	2152	4.41	0.01
DAT_STATUS_FAT_ATRASO	16644398	703949	2575	4.23	0.02
VAL_FAT_ABERTO_LIQ_ATRASO	16644398	20223	58701	0.12	0.35
SAFRA_ATRASO	16644398	0	16	0.0	0.0
DAT_CRIACAO_DW_ATRASO	16644398	0	170800	0.0	1.03
DAT_ATIVACAO_CONTA_CLI_ATRASO	16644398	0	7201	0.0	0.04
VAL_FAT_LIQ_JM_MC_ATRASO	16644398	555	58054	0.0	0.35
VAL_PARC_APARELHO_LIQ_ATRASO	16644398	0	380	0.0	0.0
VAL_MULTA_CANCELAMENTO_ATRASO	16644398	0	7360	0.0	0.04
VAL_MULTA_JUROS_ATRASO	16644398	0	4434	0.0	0.03
VAL_FAT_ABERTO_ATRASO	16644398	0	61401	0.0	0.37
VAL_FAT_PAGAMENTO_BRUTO_ATRASO	16644398	0	17468	0.0	0.1
VAL_FAT_BRUTO_BC_ATRASO	16644398	0	60312	0.0	0.36
VAL_FAT_AJUSTE_ATRASO	16644398	0	6318	0.0	0.04
VAL_FAT_CREDITO_ATRASO	16644398	0	23312	0.0	0.14
VAL_FAT_BRUTO_ATRASO	16644398	0	69979	0.0	0.42
VAL_FAT_LIQUIDO_ATRASO	16644398	0	60761	0.0	0.37
IND_FRAUDE_ATRASO	16644398	0	2	0.0	0.0

7.2.3.1 Variáveis-Chave (1)

- NUM_CPF – Identificador único do cliente

7.2.3.2 Variáveis Numericas(12)

- VAL_FAT_LIQUIDO_ATRASO – Valor da fatura após créditos e ajustes, antes de multas e juros.
- VAL_FAT_BRUTO_ATRASO – Valor total original da fatura, antes de qualquer desconto, crédito, ajuste ou pagamento.
- VAL_FAT_CREDITO_ATRASO – Valor de créditos aplicados à fatura, como bônus, compensações, abatimentos comerciais, estornos.
- VAL_FAT_AJUSTE_ATRASO – Ajustes manuais ou sistêmicos na fatura, positivos ou negativos, não classificados como crédito padrão.
- VAL_FAT_BRUTO_BC_ATRASO – Valor bruto da fatura na base de cobrança (BC).
- VAL_FAT_PAGAMENTO_BRUTO_ATRASO – Valor efetivamente pago pelo cliente, sem considerar estornos posteriores.
- VAL_FAT_ABERTO_ATRASO – Valor ainda em aberto, considerando pagamentos realizados, mas antes de ajustes finais.
- VAL_FAT_ABERTO_LIQ_ATRASO – Valor em aberto líquido, após créditos finais, ajustes, possíveis renegociações.
- VAL_MULTA_JUROS_ATRASO – Valor acumulado de multa por atraso, juros moratórios.
- VAL_MULTA_CANCELAMENTO_ATRASO – Multa aplicada por cancelamento antecipado, quebra de contrato, encerramento de linha/plano.

- VAL_PARC_APARELHO_LIQ_ATRASO – Valor líquido das parcelas de aparelho (ex.: smartphone financiado).
- VAL_FAT_LIQ_JM_MC_ATRASO – Valor da fatura líquida incluindo juros e multas.

7.2.3.3 Variáveis Categorias (20)

- CONTRATO_ATRASO – Identificador do contrato associado ao atraso
- DW_UN_NEGOCIO_ATRASO – Unidade de negócio responsável pelo cliente
- DW_HIS_PONTO_VENDA_COMTA_ATRASO – Histórico do ponto de venda onde a conta foi originada
- DW_AREA_ATRASO – Área geográfica ou organizacional do cliente
- DW_CICLO_ATRASO – Ciclo de faturamento do cliente
- DW_TIPO_CLIENTE_CONTA_ATRASO – Tipo de cliente (ex.: Pré, Pós, Controle)
- DW_OFERTA_ATRASO – Oferta ou plano contratado
- DW_FAIXA_AGING_FATURA_ATRASO – Faixa de dias de atraso da fatura
- DW_FAIXA_AGING_DIVIDA_ATRASO – Faixa de aging da dívida total
- DW_FAIXA_TEMPO_BASE_ATRASO – Faixa de tempo desde entrada na base
- DW_FAIXA_AGING_PROX_FECH_ATRASO – Faixa de aging até o próximo fechamento
- DW_TIPO_FATURAMENTO_ATRASO – Forma de faturamento (boleto, débito, etc.)
- COD_PLATAFORMA_ATRASO – Plataforma/sistema de origem do cliente
- IND_ISENCAO_COB_FAT_ATRASO – Indica isenção de cobrança da fatura
- IND_WO_ATRASO – Indica write-off da dívida
- IND_PDD_ATRASO – Indica provisão para devedores duvidosos
- IND_PCCR_ATRASO – Indica renegociação / política de cobrança
- IND_ACA_ATRASO – Indica ação de cobrança ativa
- IND_PRIMEIRA_FAT_ATRASO – Indica primeira fatura do cliente
- IND_FRAUDE_ATRASO – Indica suspeita/confirmação de fraude

7.2.3.4 Variáveis de Data (12)

- DAT_REFERENCIA_ATRASO – Data de referência usada para medir o status do atraso
- DAT_CRIACAO_REGISTRO_TRANS_ATRASO – Data de criação do registro de atraso no sistema transacional
- DAT_ALTERACAO_REGISTRO_TRANS_ATRASO – Data da última alteração do registro de atraso
- DAT_CANCELAMENTO_FAT_ATRASO – Data de cancelamento da fatura
- DAT_ORIGINAL_VCTO_FAT_ATRASO – Data de vencimento original da fatura
- DAT_ALTERACAO_VCTO_FAT_ATRASO – Data em que o vencimento foi alterado
- DAT_CRIACAO_FAT_ATRASO – Data de criação/emissão da fatura
- DAT_VENCIMENTO_FAT_ATRASO – Data de vencimento vigente da fatura

- DAT_STATUS_FAT_ATRASO – Data de encerramento do status da fatura (pagamento/baixa)
- DAT_MIN_VENCIMENTO_FAT_ATRASO – Menor vencimento associado ao contrato/fatura
- DAT_ATIVACAO_CONTA_CLI_ATRASO – Data de ativação da conta do cliente
- DAT_CRIACAO_DW_ATRASO – Data de criação do registro no Data Warehouse

7.2.4 Dicionário Técnico das Variáveis Criadas (36)

Variável	Definição	Fórmula / Regra	Pergunta que Responde
SAFRA_ATRASO	Mês de referência do atraso (YYYYMM)	F.date_format("DAT_REFERENCIA_ATRASO", "yyyyMM")	Em qual período o atraso ocorreu?
QTD_FATURAS_ATRASO	Número de faturas em atraso na safra	F.count("**")	Quantas vezes o cliente atrasou no mês?
MAX_DIAS_ATRASO	Maior atraso em dias na safra	F.max("DIAS_ATRASO")	Qual foi o pior atraso do cliente no período?
AVG_DIAS_ATRASO	Média de dias de atraso	F.avg("DIAS_ATRASO")	O atraso típico do cliente é leve ou severo?
MIN_DIAS_ATRASO	Menor atraso em dias	F.min("DIAS_ATRASO")	Houve atraso pontual ou recorrente?
STD_DIAS_ATRASO	Variabilidade dos dias de atraso	F.stddev("DIAS_ATRASO")	O comportamento de atraso é estável ou volátil?
MEDIANA_DIAS_ATRASO	Mediana dos dias de atraso	F.expr("percentile(DIAS_ATRASO, 0.5)")	O atraso típico é influenciado por extremos?
P90_DIAS_ATRASO	Percentil 90 dos dias de atraso	F.expr("percentile(DIAS_ATRASO, 0.9)")	O cliente apresenta atrasos extremos?
SEVERIDADE_ATRASO	Classificação do atraso (Baixa/Média/Alta/Crítica)	F.when(F.col("MAX_DIAS_ATRASO") <= 5, "BAIXA") .when(F.col("MAX_DIAS_ATRASO") <= 30, "MEDIA") .when(F.col("MAX_DIAS_ATRASO") <= 60, "ALTA") otherwise("CRITICA")	O atraso do cliente exige atenção especial?
SUM_FAT_LIQ	Valor líquido total faturado em atraso	F.sum("VAL_FAT_LIQUIDO_ATRASO")	Qual o valor líquido exposto ao atraso?
SUM_FAT_BRUTO	Valor bruto total faturado em atraso	F.sum("VAL_FAT_BRUTO_ATRASO")	Qual o valor bruto sob risco?
SUM_ABERTO	Valor total em aberto	F.sum("VAL_FAT_ABERTO_ATRASO")	Quanto ainda não foi pago?
SUM_ABERTO_LIQ	Valor líquido ainda em aberto	F.sum("VAL_FAT_ABERTO_LIQ_ATRASO")	Qual o valor real pendente?
SUM_PAGO_BRUTO	Valor total já pago	F.sum("VAL_FAT_PAGAMENTO_BRUTO_ATRASO")	O cliente pagou parte da dívida?
SUM_JUROS	Total de multas e juros	F.sum("VAL_MULTA_JUROS_ATRASO")	O atraso está gerando penalidades?
SUM_MULTA_CANCEL	Total de multas de cancelamento	F.sum("VAL_MULTA_CANCELAMENTO_ATRASO")	Houve penalidade contratual?
SUM_PARC_APARELHO	Total de parcelas de aparelho	F.sum("VAL_PARC_APARELHO_LIQ_ATRASO")	O atraso envolve financiamento de aparelho?
RATIO_ABERTO_LIQ	Aberto líquido / faturado líquido	F.col("SUM_ABERTO_LIQ") / F.col("SUM_FAT_LIQ")	Quanto da fatura permanece inadimplente?
RATIO_JUROS	Juros / faturado líquido	F.col("SUM_JUROS") / F.col("SUM_FAT_LIQ")	O atraso está "encarecendo" a dívida?
RATIO_PAGAMENTO	Pago bruto / faturado bruto	F.col("SUM_PAGO_BRUTO") / F.col("SUM_FAT_BRUTO")	O cliente demonstra esforço de pagamento?
MAX_DIAS_ATRASO_SAFRA	Maior atraso observado na safra	F.max("DIAS_ATRASO")	Houve atraso relevante neste mês?
FLG_ATRASO_SAFRA	Indica se houve atraso na safra (0/1)	F.when(F.col("MAX_DIAS_ATRASO_SAFRA") > 0, 1).otherwise(0)	O cliente atrasou neste período?
QTD_SAFRAS_ATRASO	Total de safras com atraso no histórico	window_cpf = Window.partitionBy("NUM_CPF") F.sum("FLG_ATRASO_SAFRA").over(window_cpf)	O cliente é recorrente em atraso?
FLG_WO	Indica write-off na safra	F.max(F.col("IND_WO_ATRASO").cast("int"))	A dívida foi considerada perda?
FLG_PDD	Indica provisão para devedores duvidosos	F.max(F.col("IND_PDD_ATRASO").cast("int"))	Cliente classificado como alto risco?
FLG_ACAO_COB	Indica ação ativa de cobrança	F.max(F.col("IND_ACA_ATRASO").cast("int"))	O cliente está sob cobrança ativa?
FLG_FRAUDE	Indica suspeita/confirmação de fraude	F.max(F.col("IND_FRAUDE_ATRASO").cast("int"))	O atraso pode estar associado a fraude?
FLG_PRIMEIRA_FAT	Indica atraso na primeira fatura	F.max(F.col("IND_PRIMEIRA_FAT_ATRASO").cast("int"))	Cliente novo já apresentou risco?
DW_UN_NEGOCIO_ATRASO	Unidade de negócio do cliente	w = Window.partitionBy("NUM_CPF", "SAFRA_ATRASO").orderBy(F.desc("DAT_REFERENCIA_ATRASO")) df_cat = (df	Qual BU concentra mais atrasos?
DW_AREA_ATRASO	Área/região do cliente		Há concentração regional de risco?

DW_TIPO_CLIENTE_CONTA_ATRASO	Tipo de cliente (pré/pós/controle)	.withColumn("RN", F.row_number().over(w)) .filter("RN = 1") .select("NUM_CPF", "SAFRA_ATRASO", "DW_UN_NEGOCIO_ATRASO", "DW_AREA_ATRASO", "DW_TIPO_CLIENTE_CONTA_ATRASO", "DW_CICLO_ATRASO", "DW_TIPO_FATURAMENTO_ATRASO", "DW_OFERTA_ATRASO", "DW_FAIXA_AGING_FATURA_ATRASO", "DW_FAIXA_AGING_DIVIDA_ATRASO")	O perfil do cliente influencia inadimplência?
DW_CICLO_ATRASO	Ciclo de faturamento		O ciclo impacta o atraso?
DW_TIPO_FATURAMENTO_ATRASO	Forma de cobrança		Meio de pagamento afeta atraso?
DW_OFERTA_ATRASO	Oferta/plano contratado		Algum plano é mais arriscado?
DW_FAIXA_AGING_FATURA_ATRASO	Faixa de aging da fatura		O atraso é recente ou avançado?
DW_FAIXA_AGING_DIVIDA_ATRASO	Faixa de aging da dívida		A dívida está envelhecendo?

7.2.5 Variáveis de Janela Temporal

As variáveis de janela capturam intensidade e tendência de comportamento em diferentes horizontes temporais (1, 3, 6, 9 e 12 meses), permitindo análises dinâmicas e redução de ruído pontual.

Variável	Definição	Fórmula / Regra	Pergunta que Responde
mean_QTD_FATURAS_ATRASO_u{months}m	Média da quantidade de faturas em atraso	F.avg("QTD_FATURAS_ATRASO").over(w).alias("mean_QTD_FATURAS_ATRASO_u{months}m")	Qual a intensidade média da quantidade de faturas em atraso nos últimos {months} meses?
mean_SUM_ABERTO_u{months}m	Média da soma do valor em aberto	F.avg("SUM_ABERTO").over(w).alias("mean_SUM_ABERTO_u{months}m")	Qual a intensidade média da soma do valor em atraso nos últimos {months} meses?
mean_QTD_SAFRAS_ATRASO_u{months}m	Média da quantidade de safras em atraso	F.avg("QTD_SAFRAS_ATRASO").over(w).alias("mean_QTD_SAFRAS_ATRASO_u{months}m")	Qual a intensidade média da quantidade de safras em atraso?
freq_QTD_FATURAS_ATRASO_u{months}m	Contagem de faturas em atraso	F.count("QTD_FATURAS_ATRASO").over(w).alias("freq_QTD_FATURAS_ATRASO_u{months}m")	Quantas faturas o cliente fica em atraso no período?
freq_QTD_SAFRAS_ATRASO_u{months}m	Contagem de safras em atraso	F.count("QTD_SAFRAS_ATRASO").over(w).alias("freq_QTD_SAFRAS_ATRASO_u{months}m")	Quantas safras o cliente fica em atraso no período?
std_SUM_ABERTO_u{months}m	Desvio padrão da soma do valores em aberto	F.stddev("SUM_ABERTO").over(w).alias("std_SUM_ABERTO_u{months}m")	Qual a variabilidade da soma do valor em aberto?
cumsum_QTD_FATURAS_ATRASO_u{months}m	Soma total da quantidade de faturas em atraso	F.sum("QTD_FATURAS_ATRASO").over(w).alias("cumsum_QTD_FATURAS_ATRASO_u{months}m")	Qual o total da soma da quantidade de faturas em atraso no período?
cumsum_SUM_ABERTO_u{months}m	Soma total da soma do valor em aberto	F.sum("SUM_ABERTO").over(w).alias("cumsum_SUM_ABERTO_u{months}m")	Qual o total da soma do valor em aberto no período?
skewness_QTD_FATURAS_ATRASO_u{months}m	Assimetria da quantidade de fatura em atraso	F.skewness("QTD_FATURAS_ATRASO").over(w).alias("skewness_QTD_FATURAS_ATRASO_u{months}m")	Como está a distribuição da quantidade de faturas em aberto no período?
skewness_SUM_ABERTO_u{months}m	Assimetria da soma do valor em aberto	F.skewness("SUM_ABERTO").over(w).alias("skewness_SUM_ABERTO_u{months}m")	Como está a distribuição da soma do valor em aberto no período?
skewness_QTD_SAFRAS_ATRASO_u{months}m	Assimetria da quantidade de safras em aberto	F.skewness("QTD_SAFRAS_ATRASO").over(w).alias("skewness_QTD_SAFRAS_ATRASO_u{months}m")	Como está a distribuição da quantidade de safra em aberto no período?
qtd_meses_FLG_ATRASO_SAFRA_u{months}m	Persistência do atraso das safras	F.sum("FLG_ATRASO_SAFRA").over(w).alias("qtd_meses_FLG_ATRASO_SAFRA_u{months}m")	Como está a frequência acumulada da quantidade de atrasos na fatura?
FLG_ATRASO_SAFRA_u{months}m	Indicador de atraso na safra no período	F.max("FLG_ATRASO_SAFRA").over(w).alias("FLG_ATRASO_SAFRA_u{months}m")	O comportamento de atraso ocorreu mais de uma vez?

7.2.6 Observações Finais

Este book de atrasos permite compreender, de forma estruturada e consistente, o comportamento de inadimplência dos clientes ao longo do tempo, identificando quem atrasa, com que intensidade, com que frequência e com qual impacto financeiro. A partir da granularidade por CPF e safra, o conjunto de variáveis captura não apenas a ocorrência do atraso, mas também sua persistência, severidade e evolução histórica, possibilitando a diferenciação entre atrasos pontuais e inadimplência recorrente. O book fornece, assim, uma base robusta e interpretável para análises de risco, modelagem preditiva e suporte às decisões de crédito e cobrança.

Dimensão	O que analisa	Perguntas de negócio respondidas	Variáveis
Identificação temporal	Posição do atraso no tempo e maturidade do cliente	Em que momento do ciclo o atraso ocorre? O cliente é novo ou maduro?	safra_atraso, ano_safra_atraso, mes_safra_atraso, tempo_base_meses
Intensidade do atraso	Gravidade do atraso em dias	O cliente atrasa pouco ou muito? Qual o nível médio e máximo de atraso?	dias_atraso_medio, dias_atraso_max, dias_atraso_min, dias_atraso_std
Persistência do atraso	Recorrência do atraso ao longo da safra	O atraso é pontual ou recorrente?	qtd_faturas_atraso, perc_faturas_atraso, flag_atraso_recorrente
Pior cenário histórico	Situação mais crítica observada	Qual foi o pior atraso já observado para o cliente?	pior_faixa_aging_fatura, pior_faixa_aging_divida, max_dias_atraso_historico
Evolução / tendência	Direção do comportamento ao longo do tempo	O atraso está piorando ou melhorando?	tendencia_dias_atraso, tendencia_valor_aberto, delta_dias_atraso
Exposição financeira	Valor financeiro associado ao atraso	Quanto dinheiro está exposto ao risco de atraso?	val_fat_bruto_total, val_fat_liquido_total, val_fat_aberto_total
Severidade financeira	Peso do atraso em relação ao faturamento	O atraso representa uma parcela relevante da fatura?	ratio_aberto_faturado, ratio_aberto_liquido, severidade_financeira
Encargos e penalidades	Multas, juros e cancelamentos	O atraso gera custo adicional relevante?	val_multa_juros_total, ratio_juros_faturado, val_multa_cancelamento_total
Esforço de pagamento	Relação entre pagamento e dívida	O cliente paga parcialmente? Reduz a dívida ao longo do tempo?	val_pagamento_total, ratio_pagamento_faturado
Estrutura da fatura	Composição da fatura	O atraso está ligado a crédito, ajuste ou parcelamento?	val_fat_credito_total, val_fat_ajuste_total, val_parc_aparelho_total
Perfil do cliente	Tipo e contexto do cliente	Certos perfis atrasam mais?	tipo_cliente_dominante, oferta_dominante, tipo_faturamento_dominante
Perfil operacional	Canal, área e ciclo	O atraso depende de operação ou canal?	area_dominante, ciclo_dominante, ponto_venda_dominante
Flags críticas	Eventos de risco ou exceção	Há sinais de risco elevado ou tratamento especial?	flag_fraude, flag_wo, flag_pdd, flag_pccr, flag_aca
Primeira fatura	Comportamento inicial do cliente	O cliente já começou atrasando?	flag_primeira_fatura_atraso
Isenção e exceções	Regras comerciais especiais	O atraso foi mitigado por isenção?	flag_isencao_cobranca
Status e cancelamento	Encerramento ou mudança de status	O atraso levou a cancelamento ou mudança contratual?	flag_cancelamento_fatura, flag_status_critico
Qualidade histórica	Estabilidade do comportamento	O cliente é consistentemente bom ou ruim?	indice_historico_atraso, score_persistencia_atraso

Dimensão	O que analisa	Perguntas de negócio respondidas	Variáveis
Identificação temporal	Posição do atraso no tempo e maturidade do cliente	Em que momento do ciclo o atraso ocorre? O cliente é novo ou maduro?	safra_atraso, ano_safra_atraso, mes_safra_atraso, tempo_base_meses
Intensidade do atraso	Gravidade do atraso em dias	O cliente atrasa pouco ou muito? Qual o nível médio e máximo de atraso?	dias_atraso_medio, dias_atraso_max, dias_atraso_min, dias_atraso_std
Persistência do atraso	Recorrência do atraso ao longo da safra	O atraso é pontual ou recorrente?	qtd_faturas_atraso, perc_faturas_atraso, flag_atraso_recorrente
Pior cenário histórico	Situação mais crítica observada	Qual foi o pior atraso já observado para o cliente?	pior_faixa_aging_fatura, pior_faixa_aging_divida, max_dias_atraso_historico
Evolução / tendência	Direção do comportamento ao longo do tempo	O atraso está piorando ou melhorando?	tendencia_dias_atraso, tendencia_valor_aberto, delta_dias_atraso
Exposição financeira	Valor financeiro associado ao atraso	Quanto dinheiro está exposto ao risco de atraso?	val_fat_bruto_total, val_fat_liquido_total, val_fat_aberto_total
Severidade financeira	Peso do atraso em relação ao faturamento	O atraso representa uma parcela relevante da fatura?	ratio_aberto_faturado, ratio_aberto_liquido, severidade_financeira
Encargos e penalidades	Multas, juros e cancelamentos	O atraso gera custo adicional relevante?	val_multa_juros_total, ratio_juros_faturado, val_multa_cancelamento_total
Esforço de pagamento	Relação entre pagamento e dívida	O cliente paga parcialmente? Reduz a dívida ao longo do tempo?	val_pagamento_total, ratio_pagamento_faturado
Estrutura da fatura	Composição da fatura	O atraso está ligado a crédito, ajuste ou parcelamento?	val_fat_credito_total, val_fat_ajuste_total, val_parc_aparelho_total
Perfil do cliente	Tipo e contexto do cliente	Certos perfis atrasam mais?	tipo_cliente_dominante, oferta_dominante, tipo_faturamento_dominante
Perfil operacional	Canal, área e ciclo	O atraso depende de operação ou canal?	area_dominante, ciclo_dominante, ponto_venda_dominante
Flags críticas	Eventos de risco ou exceção	Há sinais de risco elevado ou tratamento especial?	flag_fraude, flag_wo, flag_pdd, flag_pccr, flag_aca
Primeira fatura	Comportamento inicial do cliente	O cliente já começou atrasando?	flag_primeira_fatura_atraso
Isenção e exceções	Regras comerciais especiais	O atraso foi mitigado por isenção?	flag_isencao_cobranca
Status e cancelamento	Encerramento ou mudança de status	O atraso levou a cancelamento ou mudança contratual?	flag_cancelamento_fatura, flag_status_critico
Qualidade histórica	Estabilidade do comportamento	O cliente é consistentemente bom ou ruim?	indice_historico_atraso, score_persistencia_atraso

7.3 Pagamentos (Versão Analítica e Executiva)

7.3.1 Visão Executiva

Este documento apresenta o Book de Variáveis de Pagamentos, desenvolvido para reconstruir o comportamento financeiro dos clientes ao longo do tempo, indo além da análise binária de “pagou ou não pagou”.

O book consolida informações transacionais de pagamentos em métricas analíticas agregadas na granularidade CPF × Safra de Pagamento, permitindo compreender quando, como, quanto e com que estabilidade os clientes realizam seus pagamentos, bem como identificar sinais precoces de risco, inadimplência, churn e dependência de incentivos.

A construção do book segue uma lógica evolutiva: parte de eventos transacionais brutos, aplica filtros de qualidade, relevância e completude, e transforma esses registros em indicadores comportamentais, financeiros e operacionais, prontos para consumo analítico

7.3.2 Evolução da Base de Dados

- Base original de pagamentos: 21.829.628 registros, 73 colunas.
- Base score full: 3.590.459 CPFs distintos (6 safras).
- Safras analisadas (202410 a 202501): 2.462.481 CPFs válidos.
- Após cruzamento com pagamentos: 15.807.946 registros e 1.547.887 CPFs.
- Após exclusão de safras OOT (202502, 202503, 202504): 12.048.943 registros e 1.132.414 CPFs.
- Safras finais de pagamento: out/23 a jan/25 (16 safras).
- Adotamos o campo DAT_CRIACAO_DW_PAG para criação da variável SAFRA_PAGAMENTO por representar o momento em que o pagamento é efetivamente reconhecido pelo sistema.

7.3.3 Variáveis Brutas da Base (35)

As variáveis brutas foram avaliadas quanto à cardinalidade, preenchimento e relevância analítica. Campos com valor único, predominância extrema ou alta cardinalidade sem ganho analítico, além de variáveis técnicas, não serão incluídos no book.

Campos não incluídos [38]:

Identificadores técnicos [11]:

CONTRATO PÁG,
SEQ_FATURA_PAG,
NUM_SUB_SEQ_FATURA_PAG,
NUM_CREDITO_SEQ_PAG,
DW_NUM_CLIENTE_PAG,
SEQ_ENTIDADE_ATIVIDADE_PAG,
SEQ_ENTIDADE_PAGAMENTO_PAG,
SEQ_ARQUIVO_PAGAMENTO_PAG,
SEQ_PAGAMENTO_CREDITO_PAG,
SEQ_FATURA_CREDITO_PAG,
SEQ_ENT

IDADE_CREDITO_PAG,

Códigos de sistemas internos [16]:

COD_ORIGEM_NETUNO_PAG,
COD_CONTA_ATIVIDADE_PAG,
COD_LOGIN_OPERADOR_ATIVIDADE_PAG,
COD_ATIVIDADE_PAG,
COD_RAZAO_ATIVIDADE_PAG,
COD_FUNDO_ATIVIDADE_PAG,
COD_BANCO_ATIVIDADE_PAG,
COD_AGENCIA_ATIVIDADE_PAG,
COD_LOGIN_PAGAMENTO_PAG,
COD_ARQUIVO_PAGAMENTO_PAG,
COD_NETUNO_PAGAMENTO_PAG,
COD_LOGIN_CREDITO_PAG,
COD_ALOCACAO_CREDITO_PAG,
COD_DESALOCACAO_CREDITO_PAG,
DW_MOTIVO_ESTORNO_PAG,
COD_ORIGEM_NETUNO_PAG

Descrições textuais administrativas [2]:

DSC_PAGAMENTO_PAG,
DSC_NOME_BANCO_PAGAMENTO_PAG

Sequenciais (banco, agência etc.) [6].:

NUM_BANCO_PAGAMENTO_PAG,
NUM_AGENCIA_PAGAMENTO_PAG,
NUM_CC_PAGAMENTO_PAG,
NUM_CONTA_ATIVIDADE_PAG,
NUM_PARCELA_PAGAMENTO_PAG,
NUM_AGRUPADOR_PAGAMENTO_PAG

Campos com missing [3]:

Com relação aos nulos das colunas temos que 3 colunas apresentam nulos acima de 80% e por isso não serão utilizadas:

DAT_ATUALIZACAO_CREDITO_PAG : 8.002.294 (100.0)
DAT_ATUALIZACAO_ATIVIDADE_PAG: 7.456.681 (93.18)
DAT_ATUALIZACAO_PAGAMENTO_PAG: 6.453.665 (80.65)

7.3.3.1 Variáveis-Chave (1)

- NUM_CPF – Identificador único do cliente

7.3.3.2 Variáveis Numericas (11)

- VAL_PAGAMENTO_FATURA_PAG – Valor total pago referente à fatura
- VAL_DESCONTO_ITEM_PAG – Valor de desconto aplicado ao item
- VAL_PAGAMENTO_ITEM_PAG – Valor pago por item da fatura
- VAL_JUROS_MULTAS_ITEM_PAG – Valor de juros e multas aplicados ao item
- VAL_MULTA_EQUIP_ITEM_PAG – Multa aplicada ao item relacionada a equipamento
- VAL_MULTA_EQUIP_TOTAL_PAG – Valor total de multas de equipamento
- VAL_MULTA_FID_ITEM_PAG – Multa por fidelização aplicada ao item
- VAL_BAIXA_ATIVIDADE_PAG – Valor efetivamente baixado/compensado
- VAL_ORIGINAL_PAGAMENTO_PAG – Valor original do pagamento antes de ajustes
- VAL_ATUAL_PAGAMENTO_PAG – Valor atualizado do pagamento
- VAL_PAGAMENTO_CREDITO_PAG – Valor pago utilizando crédito

7.3.3.3 Variáveis Categorias (13)

- DW_TIPO_FATURA_PAG – Tipo da fatura
- IND_STATUS_FATURA_PAG – Status da fatura
- DW_AREA_PAG – Identifica a área/origem responsável do processo de cobrança
- DW_UN_NEGOCIO_PAG – Unidade de negócio do pagamento
- DW_FORMA_PAGAMENTO_PAG – Forma de pagamento (Ex: boleto, cartão, débito)
- DW_BANCO_PAG – Banco utilizado no pagamento
- DW_TIPO_PAGAMENTO_PAG – Tipo de pagamento (Ex: pagamento normal, crédito, ajuste)
- COD_FORMA_PAGAMENTO_PAG – Código da forma de pagamento
- COD_TIPO_PAGAMENTO_PAG – Código do tipo de pagamento
- COD_METODO_PAGAMENTO_PAG – Método de pagamento (meio operacional do pagamento (ex: app, agência, automático)
- IND_STATUS_PAGAMENTO_PAG – Status do pagamento (indica se o pagamento foi concluído, rejeitado, estornado)
- IND_TIPO_CREDITO_PAG – Tipo de crédito utilizado
- COD_TIPO_FATURA_PAG – Código do tipo de fatura

7.3.3.4 Variáveis de Data (10)

- DAT_STATUS_FATURA_PAG – Data do status da fatura
- DAT_CRIACAO_DW_PAG – Data de criação do registro do pagamento no DW
- DAT_CRIACAO_ATIVIDADE_PAG – Data de criação da atividade
- DAT_BAIXA_ATIVIDADE_PAG – Data da baixa da atividade
- DAT_DEPOSITO_ATIVIDADE_PAG – Data do depósito
- DAT_CRIACAO_PAGAMENTO_PAG – Data de criação do pagamento
- DAT_STATUS_PAGAMENTO_PAG – Data do status do pagamento
- DAT_CRIACAO_CREDITO_PAG – Data de criação do crédito
- DAT_ATIVIDADE_CREDITO_PAG – Data da atividade do crédito
- DAT_VENCIMENTO_CREDITO_PAG – Data de vencimento

7.3.4 Dicionário Técnico das Variáveis Criadas (63)

Variável	Definição	Fórmula / Regra	Pergunta que Responde
SAFRA_PAGAMENTO	Safra do pagamento em anomes(yyyyMM)	F.date_format(F.col("DAT_CRIACAO_DW_PAG"), "yyyyMM")	Qual o anomes do pagamento?
DT_PRIMEIRO_PAG_SAFRA	Data do primeiro pagamento realizado pelo CPF na safra	df_01.withColumn("DATA_PAGAMENTO_REF", F.col("DAT_CRIACAO_DW_PAG"), F.min("DATA_PAGAMENTO_REF"))	O cliente começou a pagar cedo ou deixou para o final? Indica comportamento proativo vs. reativo
DT_ULTIMO_PAG_SAFRA	Data do último pagamento da safra	F.max("DATA_PAGAMENTO_REF")	O cliente manteve relacionamento ativo até o fim da safra?
SPAN_DIAS_PAG_SAFRA	Média de dias de atraso dos pagamentos da safra	F.datediff(F.max("DATA_PAGAMENTO_REF"), F.min("DATA_PAGAMENTO_REF"))	Mede regularidade e dispersão dos pagamentos ao longo do tempo
MAX_DIAS_ATRASO_SAFRA	Maior atraso registrado na safra	F.max("DIAS_ATRASO")	O cliente já apresentou atraso severo? Importante para políticas de risco
AVG_DIAS_ATRASO_SAFRA	Atraso médio dos pagamentos na safra	F.avg("DIAS_ATRASO")	Qual é o nível médio de atraso do cliente? Indica risco estrutural
QTD_PAG_ATRASADOS_SAFRA	Quantidade de pagamentos com atraso (>0 dias)	F.sum(F.when(F.col("DIAS_ATRASO") > 0, 1).otherwise(0))	O atraso é pontual ou recorrente?
FLAG_ATRASO_SAFRA	Indica se houve pelo menos um atraso na safra (0/1)	F.max(F.when(F.col("DIAS_ATRASO") > 0, 1).otherwise(0))	Cliente 100% pontual ou não? Variável simples e altamente explicativa
AVG_DIAS_CRIACAO_STATUS_SAFRA	Média de dias entre criação do pagamento e status de pagamento	F.avg(F.datediff(F.col("DAT_STATUS_PAGAMENTO_PAG"), F.col("DAT_CRIACAO_PAGAMENTO_PAG")))	Mede eficiência operacional e comportamento do cliente frente à cobrança
AVG_DIAS_STATUS_DEPOSITO_SAFRA	Média de dias entre status do pagamento e depósito	F.avg(F.datediff(F.col("DAT_DEPOSITO_ATIVIDADE_PAG"), F.col("DAT_STATUS_PAGAMENTO_PAG")))	Indica possíveis gargalos operacionais ou comportamento pós-pagamento
LAG_AVG_DIAS_ATRASO	Média de atraso da safra anterior	F.lag("AVG_DIAS_ATRASO_SAFRA", 1).over(window_cpf)	Qual era o comportamento passado do cliente? Base para tendência
LAG_MAX_DIAS_ATRASO	Maior atraso da safra anterior	F.lag("MAX_DIAS_ATRASO_SAFRA", 1).over(window_cpf)	O cliente já vinha com histórico crítico?
LAG_QTD_PAG_ATRASADOS	Quantidade de atrasos na safra anterior	F.lag("QTD_PAG_ATRASADOS_SAFRA", 1).over(window_cpf)	Avalia reincidência de comportamento
LAG_FLAG_ATRASO	Indica se houve atraso na safra anterior	F.lag("FLAG_ATRASO_SAFRA", 1).over(window_cpf)	Cliente já era inadimplente recentemente?
DELTA_AVG_DIAS_ATRASO	Varição da média de atraso vs. safra anterior	F.col("AVG_DIAS_ATRASO_SAFRA") - F.col("LAG_AVG_DIAS_ATRASO")	O comportamento está melhorando ou piorando? Variável de tendência
DELTA_QTD_ATRASOS	Diferença na quantidade de atrasos entre safras	F.col("QTD_PAG_ATRASADOS_SAFRA") - F.col("LAG_QTD_PAG_ATRASADOS")	O cliente está se disciplinando ou degradando?
PERFIL_PAGAMENTO	Classificação do cliente (pontual, leve, moderado, severo)	F.when(F.col("MAX_DIAS_ATRASO_SAFRA") <= 0, "PONTUAL").when(F.col("MAX_DIAS_ATRASO_SAFRA") <= 10, "LEVE_ATRASO").when(F.col("MAX_DIAS_ATRASO_SAFRA") <= 30, "ATRASO_MODERADO").otherwise("ATRASO_SEVERO")	Facilita interpretação, segmentação e regras de negócio
FLAG_REINCIDENCIA_ATRASO	Indica atraso em safras consecutivas	F.when((F.col("FLAG_ATRASO_SAFRA") == 1) & (F.col("LAG_FLAG_ATRASO") == 1), 1).otherwise(0)	Identifica clientes estruturalmente problemáticos
FLAG_PIORA_ATRASO	Indica aumento relevante no atraso médio	F.when(F.col("DELTA_AVG_DIAS_ATRASO") > 5, 1).otherwise(0)	Sinal precoce de deterioração de risco

SUM_VAL_PAGO_SAFRA	Total pago na safra	F.sum("VAL_PAGAMENTO_FATURA_PAG")	Quanto o cliente gera de receita?
AVG_VAL_PAGO_SAFRA	Média dos pagamentos	F.avg("VAL_PAGAMENTO_FATURA_PAG")	Qual o ticket típico do cliente?
MAX_VAL_PAGO_SAFRA	Maior pagamento	F.max("VAL_PAGAMENTO_FATURA_PAG")	Pagamento concentrado ou parcelado?
MIN_VAL_PAGO_SAFRA	Menor pagamento	F.min("VAL_PAGAMENTO_FATURA_PAG")	Existem valores residuais?
QTD_PAGAMENTOS_SAFRA	Nº de pagamentos	F.count("VAL_PAGAMENTO_FATURA_PAG")	Cliente recorrente ou pontual?
TICKET_MEDIO_SAFRA	Ticket médio calculado	F.col("SUM_VAL_PAGO_SAFRA") / F.col("QTD_PAGAMENTOS_SAFRA")	Segmentação financeira
SUM_VAL_ORIGINAL_SAFRA	Valor original da dívida	F.sum("VAL_ORIGINAL_PAGAMENTO_PAG")	Qual era a dívida original do cliente?
SUM_VAL_ATUAL_SAFRA	Valor atualizado	F.sum("VAL_ATUAL_PAGAMENTO_PAG")	Houve acréscimos financeiros?
DELTA_VALOR_ORIGINAL_ATUAL	Diferença original vs atual	F.col("SUM_VAL_ATUAL_SAFRA") - F.col("SUM_VAL_ORIGINAL_SAFRA")	Endividamento crescente?
SUM_VAL_BAIXA_SAFRA	Valor efetivamente baixado	F.sum("VAL_BAIXA_ATIVIDADE_PAG")	Qualidade da liquidação
RATIO_BAIXA_SOBRE_PAGO	Baixa + pago	F.col("SUM_VAL_BAIXA_SAFRA") / F.col("SUM_VAL_PAGO_SAFRA")	Pagamento integral ou parcial?
SUM_DESCONTO_SAFRA	Total de descontos	F.sum("VAL_DESCONTO_ITEM_PAG")	Dependência de incentivo
RATIO_DESCONTO_SOBRE_PAGO	Desconto + pago	F.col("SUM_DESCONTO_SAFRA") / F.col("SUM_VAL_PAGO_SAFRA")	Fragilidade de margem
VAL_PAGO_LIQUIDO_SAFRA	Pago menos desconto	F.col("SUM_VAL_PAGO_SAFRA") - F.col("SUM_DESCONTO_SAFRA")	Receita real do cliente
SUM_JUROS_MULTAS_SAFRA	Juros e multas pagos	F.sum("VAL_JUROS_MULTAS_ITEM_PAG")	Custo financeiro do atraso
RATIO_JUROS_SOBRE_PAGO	Juros + pago	F.col("SUM_JUROS_MULTAS_SAFRA") / F.col("SUM_VAL_PAGO_SAFRA")	Penalização financeira recorrente
SUM_MULTA_EQUIP_TOTAL_SAFRA	Multas contratuais	F.sum("VAL_MULTA_EQUIP_TOTAL_PAG")	Quebra de contrato
SUM_MULTA_FID_SAFRA	Multa de fidelidade	F.sum("VAL_MULTA_FID_ITEM_PAG")	Indício de churn
RATIO_MULTAS_SOBRE_PAGO	Multas + pago	F.col("SUM_MULTA_EQUIP_TOTAL_SAFRA") + F.col("SUM_MULTA_FID_SAFRA") / F.col("SUM_VAL_PAGO_SAFRA")	Pressão financeira
STDDEV_VAL_PAGO_SAFRA	Variabilidade dos valores	F.stddev("AVG_VAL_PAGO_SAFRA").over(window_spec_cpf)	Estabilidade financeira
LAG_SUM_VAL_PAGO	Total pago safra anterior	F.lag("SUM_VAL_PAGO_SAFRA").over(window_cpf)	Histórico financeiro
DELTA_SUM_VAL_PAGO	Evolução do valor pago	F.col("SUM_VAL_PAGO_SAFRA") - F.col("LAG_SUM_VAL_PAGO")	Crescimento ou retração
PERFIL_VOLUME_FINANCEIRO	Classificação de volume	F.when(F.col("SUM_VAL_PAGO_SAFRA") < 50, "BAIXO").when(F.col("SUM_VAL_PAGO_SAFRA") < 150, "MEDIO").otherwise("ALTO")	Regras e estratégias
QTD_FORMAS_PAGAMENTO	Nº de formas distintas usadas	F.countDistinct("DW_FORMA_PAGAMENTO_PAG")	Cliente é consistente ou alterna forma de pagamento?
QTD_METODOS_PAGAMENTO	Nº de métodos distintos	F.countDistinct("COD_METODO_PAGAMENTO_PAG")	Pagamentos são simples ou complexos?
QTD_BANCOS_UTILIZADOS	Nº de bancos distintos	F.countDistinct("DW_BANCO_PAG")	Cliente centraliza ou pulveriza pagamentos?
QTD_TIPOS_PAGAMENTO	Nº de tipos distintos de pagamento	F.countDistinct("DW_TIPO_PAGAMENTO_PAG")	Pagamentos recorrentes ou variados?
QTD_TIPOS_FATURA	Nº de tipos distintos de fatura	F.countDistinct("DW_TIPO_FATURA_PAG")	Complexidade da estrutura de cobrança
FORMA_PAGAMENTO_DOMINANTE	Forma mais usada na safra	def calcular_moda(df, col, alias): return (df.groupBy("NUM_CPF", "SAFRA_PAGAMENTO", col) .agg(F.count("{}", alias("freq")) .withColumn("m", F.row_number().over(w_moda)) .filter(F.col("m") == 1) .select("NUM_CPF", "SAFRA_PAGAMENTO", F.col(col).alias(alias))) calcular_moda(df_01, "DW_FORMA_PAGAMENTO_PAG", "FORMA_PAGAMENTO_DOMINANTE")	Qual meio o cliente prefere pagar?
METODO_PAGAMENTO_DOMINANTE	Método mais frequente	calcular_moda(df_01, "COD_METODO_PAGAMENTO_PAG", "METODO_PAGAMENTO_DOMINANTE")	Preferência operacional (PIX, débito, boleto)?
BANCO_DOMINANTE	Banco mais utilizado	calcular_moda(df_01, "DW_BANCO_PAG", "BANCO_DOMINANTE")	Existe relacionamento bancário principal?
TIPO_PAGAMENTO_DOMINANTE	Tipo de pagamento mais comum	calcular_moda(df_01, "DW_TIPO_PAGAMENTO_PAG", "TIPO_PAGAMENTO_DOMINANTE")	Pagamento é recorrente ou eventual?
TIPO_FATURA_DOMINANTE	Tipo de fatura predominante	calcular_moda(df_01, "DW_TIPO_FATURA_PAG", "TIPO_FATURA_DOMINANTE")	Estrutura principal de cobrança
AREA_DOMINANTE	Área responsável	calcular_moda(df_01, "DW_AREA_PAG", "AREA_DOMINANTE")	Contexto institucional do pagamento
UN_NEGOCIO_DOMINANTE	Unidade de negócio dominante	calcular_moda(df_01, "DW_UN_NEGOCIO_PAG", "UN_NEGOCIO_DOMINANTE")	Segmento principal do cliente

QTD_STATUS_PAGO	Nº de pagamentos com status pago	F.sum(F.when(F.col("IND_STATUS_PAGAMENTO_PAG") == "C", 1).otherwise(0))	Histórico de adimplência
QTD_FATURA_PAGA	Nº de faturas pagas	F.sum(F.when(F.col("IND_STATUS_FATURA_PAG") == "C", 1).otherwise(0))	Efetividade da cobrança
RATIO_PAG_PAGOS	% de pagamentos pagos	F.col("QTD_STATUS_PAGO") / F.col("QTD_PAGAMENTOS_SAFRA")	Qualidade do comportamento financeiro
QTD_EVENTOS_CREDITO	Nº de registros com crédito	F.sum(F.when(F.col("IND_TIPO_CREDITO_PAG").isNull(), 1).otherwise(0))	Cliente recebeu crédito/ajuste?
FLAG_EVENTO_CREDITO	1 se houve crédito na safra	F.col("QTD_EVENTOS_CREDITO") > 0).cast("int")	Evento financeiro relevante ocorreu?
FLAG_MULTIPLAS_FORMAS_PAG	1 se usou mais de uma forma	F.col("QTD_FORMAS_PAGAMENTO") > 1).cast("int")	Indício de instabilidade operacional
FLAG_MULTIPLOS_BANCOS	1 se usou mais de um banco	F.col("QTD_BANCOS_UTILIZADOS") > 1).cast("int")	Fragmentação financeira
FLAG_MUDANCA_FORMA_PAG	Mudou forma vs safra anterior	F.when((F.col("FORMA_PAGAMENTO_ANT").isNull()) & (F.col("FORMA_PAGAMENTO_DOMINANTE") != F.col("FORMA_PAGAMENTO_ANT")), 1).otherwise(0))	Alteração recente de hábito?
FLAG_MUDANCA_BANCO	Mudou banco vs safra anterior	F.when((F.col("BANCO_ANT").isNull()) & (F.col("BANCO_DOMINANTE") != F.col("BANCO_ANT")), 1).otherwise(0))	Mudança estrutural financeira?

7.3.5 Variáveis de Janela Temporais

As variáveis de janela capturam intensidade e tendência de comportamento em diferentes horizontes temporais (1, 3, 6, 9 e 12 meses), permitindo análises dinâmicas e redução de ruído pontual.

Variável	Definição	Fórmula / Regra	Pergunta que Responde
mean_QTD_PAG_ATRASADOS_SAFRA_u(months)m	Média da quantidade de pagamentos atrasos na safra	F.avg("QTD_PAG_ATRASADOS_SAFRA").over(w).alias("mean_QTD_PAG_ATRASADOS_SAFRA_u(months)m")	Qual a intensidade média da quantidade de pagamentos atrasados na safra nos últimos {months} meses?
mean_QTD_PAGAMENTOS_SAFRA_u(months)m	Média da quantidade de pagamentos na safra	F.avg("QTD_PAGAMENTOS_SAFRA").over(w).alias("mean_QTD_PAGAMENTOS_SAFRA_u(months)m")	Qual a intensidade média de pagamentos na safra nos últimos {months} meses?
freq_QTD_PAG_ATRASADOS_SAFRA_u(months)m	Contagem da quantidade de pagamentos atrasados na safra	F.count("QTD_PAG_ATRASADOS_SAFRA").over(w).alias("freq_QTD_PAG_ATRASADOS_SAFRA_u(months)m")	Quanto pagamentos atrasados na safra no período?
freq_QTD_PAGAMENTOS_SAFRA_u(months)m	Contagem da quantidade de pagamentos na safra	F.count("QTD_PAGAMENTOS_SAFRA").over(w).alias("freq_QTD_PAGAMENTOS_SAFRA_u(months)m")	Quanto pagamentos na safra no período?
cumsum_QTD_PAG_ATRASADOS_SAFRA_u(months)m	Soma total da quantidade de pagamentos atrasados na safra	F.sum("QTD_PAG_ATRASADOS_SAFRA").over(w).alias("cumsum_QTD_PAG_ATRASADOS_SAFRA_u(months)m")	Qual o valor total da soma de quantidade de pagamentos atrasados na safra
cumsum_QTD_PAGAMENTOS_SAFRA_u(months)m	Soma total da quantidade de pagamentos na safra	F.sum("QTD_PAGAMENTOS_SAFRA").over(w).alias("cumsum_QTD_PAGAMENTOS_SAFRA_u(months)m")	Qual o valor total da soma de quantidade de pagamentos na safra no período?
skewness_QTD_PAG_ATRASADOS_SAFRA_u(months)m	Assimetria de quantidade de pagamentos atrasados na safra	F.skewness("QTD_PAG_ATRASADOS_SAFRA").over(w).alias("skewness_QTD_PAG_ATRASADOS_SAFRA_u(months)m")	Como está a distribuição da quantidade de pagamentos atrasados na safra no período?
skewness_QTD_PAGAMENTOS_SAFRA_u(months)m	Assimetria de quantidade de pagamentos na safra	F.skewness("QTD_PAGAMENTOS_SAFRA").over(w).alias("skewness_QTD_PAGAMENTOS_SAFRA_u(months)m")	Como está a distribuição da quantidade de pagamentos na safra no período?

qtd_meses_FLAG_ATRASO_SAFRA_u{months}m	Persistência do atraso na safra	F.sum("FLAG_ATRASO_SAFRA").over(w).alias(f"qtd_meses_FLAG_ATRASO_SAFRA_u{months}m")	Como está a frequência acumulada da quantidade de atraso na safra?
qtd_meses_FLAG_REINCIDENCIA_ATRASO_u{months}m	Persistência a reincidência do atraso	F.sum("FLAG_REINCIDENCIA_ATRASO").over(w).alias(f"qtd_meses_FLAG_REINCIDENCIA_ATRASO_u{months}m")	Como está a frequência acumulada da reincidência do atraso no período?
flg_FLAG_ATRASO_SAFRA_u{months}m	Indicador de atraso na safra	F.max("FLAG_ATRASO_SAFRA").over(w).alias(f"flg_FLAG_ATRASO_SAFRA_u{months}m")	O comportamento do atraso ocorreu mais de uma vez?
flg_FLAG_REINCIDENCIA_ATRASO_u{months}m	Indicador de reincidência de atraso	F.max("FLAG_REINCIDENCIA_ATRASO").over(w).alias(f"flg_FLAG_REINCIDENCIA_ATRASO_u{months}m")	O comportamento de reincidência em atraso no período?

7.3.6 Observações Finais

Este Book de Pagamentos, agregado na granularidade CPF + SAFRA_PAGAMENTO, permite reconstruir o comportamento financeiro completo do cliente ao longo do tempo, indo muito além do “pagou ou não pagou”.

Com ele, é possível entender:

- Quando o cliente paga (pontualidade, atraso, reincidência)
- Como o comportamento evolui entre safras (melhora, piora, estabilidade)
- Quanto ele paga (volume, ticket, crescimento ou retração)
- Qual o custo financeiro do comportamento (juros, multas, descontos)
- Quão estável é o padrão de pagamento (formas, bancos, métodos)
- Se há sinais precoces de risco, churn ou dependência de incentivo

Na prática, o book sustenta:

- modelos de risco / inadimplência
- segmentação comportamental
- políticas de cobrança

Dimensão	O que analisa	Perguntas de negócio respondidas	Variáveis
Temporal & Pontualidade	Momento e regularidade dos pagamentos	O cliente paga cedo ou no limite? Mantém pagamentos ao longo da safra?	SAFRA_PAGAMENTO, DT_PRIMEIRO_PAG_SAFRA, DT_ULTIMO_PAG_SAFRA, SPAN_DIAS_PAG_SAFRA
Atraso & Severidade	Existência, frequência e gravidade de atrasos	O cliente atrasa? Com que intensidade?	MAX_DIAS_ATRASO_SAFRA, QTD_PAG_ATRASADOS_SAFRA, FLAG_ATRASO_SAFRA
Eficiência Operacional	Tempo entre eventos do ciclo de pagamento	Há gargalos entre criação, status e depósito?	AVG_DIAS_CRIACAO_STATUS_SAFRA, AVG_DIAS_STATUS_DEPOSITO_SAFRA

Dimensão	O que analisa	Perguntas de negócio respondidas	Variáveis
Histórico & Tendência	Evolução do comportamento entre safras	O comportamento melhora ou piora ao longo do tempo?	LAG_AVG_DIAS_ATRASO, LAG_MAX_DIAS_ATRASO, LAG_QTD_PAG_ATRASADOS, DELTA_AVG_DIAS_ATRASO, DELTA_QTD_ATRASOS
Persistência de Risco	Continuidade de atraso entre safras	O atraso é estrutural ou pontual?	LAG_FLAG_ATRASO, FLAG_REINCIDENCIA_ATRASO, FLAG_PIORA_ATRASO
Perfil de Pagamento	Síntese interpretável do risco	Como classificar rapidamente o cliente?	PERFIL_PAGAMENTO
Volume Financeiro	Intensidade e padrão de pagamento	Quanto o cliente paga e com qual regularidade?	SUM_VAL_PAGO_SAFRA, AVG_VAL_PAGO_SAFRA, MIN_VAL_PAGO_SAFRA, MAX_VAL_PAGO_SAFRA, QTD_PAGAMENTOS_SAFRA, TICKET_MEDIO_SAFRA
Evolução Financeira	Crescimento ou retração do valor pago	O cliente está aumentando ou reduzindo pagamentos?	LAG_SUM_VAL_PAGO, DELTA_SUM_VAL_PAGO
Perfil Financeiro	Classificação de porte financeiro	Cliente de baixo, médio ou alto valor?	PERFIL_VOLUME_FINANCEIRO
Dívida & Liquidação	Diferença entre dívida, pagamento e baixa	O pagamento foi integral? Houve acréscimos?	SUM_VAL_ORIGINAL_SAFRA, SUM_VAL_ATUAL_SAFRA, DELTA_VALOR_ORIGINAL_ATUAL, SUM_VAL_BAIXA_SAFRA, RATIO_BAIXA SOBRE_PAGO
Custos & Penalizações	Impacto financeiro do atraso	O atraso gera custo recorrente?	SUM_JUROS_MULTAS_SAFRA, RATIO_JUROS SOBRE_PAGO
Descontos & Incentivos	Dependência de desconto	O cliente só paga com incentivo?	SUM_DESCONTO_SAFRA, RATIO_DESCONTO SOBRE_PAGO, VAL_PAGO_LIQUIDO_SAFRA
Multas & Churn	Quebras contratuais	Há indícios de churn ou penalização contratual?	SUM_MULTA_EQUIP_TOTAL_SAFRA, SUM_MULTA_FID_SAFRA, RATIO_MULTAS SOBRE_PAGO
Estabilidade Financeira	Variabilidade dos pagamentos	O cliente é financeiramente estável?	STDDEV_VAL_PAGO_SAFRA
Complexidade Operacional	Fragmentação de meios de pagamento	Pagamento simples ou pulverizado?	QTD_FORMAS_PAGAMENTO, QTD_METODOS_PAGAMENTO, QTD_BANCOS_UTILIZADOS, QTD_TIPOS_PAGAMENTO, QTD_TIPOS_FATURA
Preferências & Dominância	Padrão principal de pagamento	Qual o meio, banco e tipo predominante?	FORMA_PAGAMENTO_DOMINANTE, METODO_PAGAMENTO_DOMINANTE, BANCO_DOMINANTE, TIPO_PAGAMENTO_DOMINANTE, TIPO_FATURA_DOMINANTE
Contexto Organizacional	Origem institucional dos pagamentos	Qual área e negócio concentram o pagamento?	AREA_DOMINANTE, UN_NEGOCIO_DOMINANTE
Adimplência & Crédito	Qualidade do pagamento e ajustes	O cliente paga de fato? Recebe créditos?	QTD_STATUS_PAGO, QTD_FATURA_PAGA, RATIO_PAG_PAGOS, QTD_EVENTOS_CREDITO, FLAG_EVENTO_CREDITO
Mudança Comportamental	Alterações recentes no padrão	O cliente mudou de hábito financeiro?	FLAG_MUDANCA_FORMA_PAG, FLAG_MUDANCA_BANCO

Dimensão	O que analisa	Perguntas de negócio respondidas	Variáveis
Instabilidade Operacional	Sinais de fragmentação	Há instabilidade recente?	FLAG_MULTIPLAS_FORMAS_PAG, FLAG_MULTIPLOS_BANCOS

RELATÓRIO TÉCNICO: DESENVOLVIMENTO DE MODELO DE RISCO DE CRÉDITO

Projeto: Migração Pré-Pago para Pós-Pago (Detecção de FPD)

Versão do Modelo: V6_Final

Data: 12 de Março de 2026

1. Introdução e Escopo

Este documento registra as etapas de pré-processamento dos dados, a estruturação do modelo de Machine Learning e as principais decisões técnicas adotadas para o desenvolvimento de um modelo de classificação binária (Bom vs. Mau/Fraude). O objetivo é prever a probabilidade de ocorrência de **First Payment Default (FPD)** em novos clientes de telecomunicações solicitantes de migração de plano.

2. Pré-processamento dos Dados

2.1. Integração de Fontes de Dados

O modelo foi construído a partir da integração de múltiplas fontes de dados (Books), visando criar uma visão 360° do cliente:

- * Base Âncora: Scores de risco externos (SCORE_01, SCORE_02).
- * Telco: Dados de utilização e tráfego.
- * Cadastro: Informações demográficas e dados estáticos.
- * Comportamental: Books de Recarga, Pagamento e Atraso (histórico temporal).

2.2. Limpeza e Tratamento de Dados

- * Tratamento de Códigos Especiais (Telco): Identificamos códigos específicos (`304`, `303`, `0`, `100`) na base de telco que representavam ausência de informação ou dados faltantes. Estes foram transformados em *flags* binárias (ex: `tel_var_X_is_304`) para capturar o padrão de ausência, e o valor original foi convertido para `NaN`.
- * Tratamento de Datas: Variáveis de data (nascimento, primeira recarga, vencimento) foram convertidas para variáveis numéricas de "dias até a data de referência". Isso transformou a temporalidade em magnitude, permitindo que o modelo entendesse a antiguidade do cliente e a recência dos eventos.
- * Agregações Temporais (Books): Para os dados de Recarga, Pagamento e Atraso, foram criadas variáveis derivadas (features) utilizando janelas temporais (3 meses, 6 meses, 12 meses), incluindo estatísticas como soma, média, desvio padrão, mínimo e máximo. Isso capturou o comportamento financeiro e de uso ao longo do tempo.
- * Otimização de Memória: Variáveis numéricas foram convertidas para `float32` e flags para `int8` para garantir eficiência computacional.

2.3. Tratamento de Variáveis Categóricas

- * Decisão Técnica: Diferente de abordagens tradicionais de Label Encoding (conversão manual para números inteiros), optamos por manter as variáveis categóricas (strings) no formato nativo `category` do Pandas.
- * Justificativa: O algoritmo escolhido (LightGBM) lida nativamente com categorias, preservando a semântica dos dados e evitando erros de alinhamento entre as bases de Treino e Validação/OOT, onde novas categorias podem surgir.

3. Engenharia de Features e Seleção

3.1. Construção de Features

Foram geradas inicialmente mais de 1.300 variáveis contando com o trabalho feito pela Engenharia de Dados, que gerou quase 500 variáveis (detalhamento na construção dos books), incluindo:

- * **Flags de Risco:** Indicadores de atrasos no janelamento de 1, 3, 6, 9 e 12 meses quando a variável ou o book permitiu.
- * **Razões e Taxas:** Porcentagem de recargas com bônus, percentual de SOS (Sem Saldo) no período.
- * **Diferenças Temporais:** Gap entre a última recarga e a data de referência (desvio de recência).

Com o tratamento, as variáveis saem de 838 (originais e construídas) para 1314.

Modelo	Variáveis + increm.	KS	Ganho KS
V01	Score_01	0,2664	-
V02	+ Score_02	0,3236	+ 0,0572
V03	+ Telco = (343)	0,3277	+ 0,0041
V04	Scores + Telco + Cadastro = (363)	0,3300	+ 0,0023
V05	Scores + Telco + Cadastro + Book_recarga= (838)	0,3665	+ 0,0365
V06_final	Scores + Telco + Cadastro + Book_recarga + Book_atraso + Book_pagamento 1.314 vars → 50 finais	0,3776	+ 0,0111
V06_final (OOT)	50 finais	0,36	estável

3.2. Seleção de Variáveis (Feature Selection)

Para evitar overfitting e garantir performance em produção, foi realizada uma seleção rigorosa:

1. Eliminação de variáveis com importância zero (Gain) fornecida pelo LightGBM.
2. Análise de correlação (threshold > 0.90) para remover redundâncias.

3. Decisão Final: Seleção das Top 50 variáveis mais importantes. Isso reduziu a complexidade do modelo, melhorou a estabilidade (PSI) e facilitou a explicabilidade (SHAP), mantendo o poder preditivo.

4. Estruturação do Modelo de Machine Learning

4.1. Escolha do Algoritmo: LightGBM

Justificativa:

Optou-se pelo **LightGBM (Light Gradient Boosting Machine)** pelos seguintes motivos:

1. Performance: É o estado da arte para dados tabulares estruturados, superando frequentemente Random Forests e XGBoost em velocidade e acurácia.
2. Tratamento Nativo: Lida nativamente com valores faltantes (NaN) e variáveis categóricas, reduzindo a necessidade de pré-processamento complexo.
3. Eficiência: Possui baixo consumo de memória e alta velocidade de treinamento, essencial para grandes volumes de dados.
4. Interpretabilidade: Permite o cálculo de Feature Importance (Gain) e valores SHAP para explicar as decisões do modelo.

4.2. Configuração e Hiperparâmetros

O modelo foi configurado como um classificador binário (`objective='binary'`). Ajustes finos (Fine-tuning) foram realizados para controlar o overfitting:

- * `max_depth=5`: Limitou a profundidade das árvores para evitar que o modelo decorasse o ruído dos dados de treino.
- * `learning_rate=0.03`: Taxa de aprendizado baixa combinada com alto número de estimadores para convergência suave.
- * `scale_pos_weight`: Ajustado automaticamente para lidar com o desbalanceamento das classes (eventos de FPD são raros), penalizando mais erros na classe minoritária.
- * **Regularização**: Uso de `reg_alpha` (L1) e `reg_lambda` (L2) para simplificar o modelo.
- * **Early Stopping**: O treinamento foi interrompido automaticamente se a métrica de validação (AUC) não melhorasse por 50 rodadas consecutivas, prevenindo overfitting.

SEED = 42

```
model_refined = lgb.LGBMClassifier(  
    random_state=SEED,  
    n_estimators=1500,  
    learning_rate=0.03,  
    max_depth=5,  
    min_child_samples=100,  
    subsample=0.7,  
    colsample_bytree=0.7,  
    reg_alpha=0.5,  
    reg_lambda=3.0,  
    objective='binary',  
    metric='auc',  
    n_jobs=4,  
    verbose=-1,  
    scale_pos_weight=(len(y_train) - sum(y_train)) / sum(y_train)  
)  
  
model_refined.fit(  
    X_train_sel, y_train,  
    eval_set=[(X_oos_sel, y_oos)],  
    eval_metric='auc',  
    categorical_feature=cat_cols_refined, # <--- Use a lista dinâmica, não a antiga 'all_cat_features'  
    callbacks=[lgb.early_stopping(stopping_rounds=50, verbose=True)]  
)
```


5. Metodologia de Validação

Adotou-se uma estratégia de validação temporal para garantir robustez:

1. Treino: Dados de Outubro a Dezembro 2024 (desenvolvimento e aprendizado dos padrões).
2. OOS (Out-of-Sample): Dados de Janeiro 2025 (ou período imediatamente seguinte) utilizado para ajuste de hiperparâmetros e validação técnica.
3. OOT (Out-of-Time): Dados de Fevereiro e Março 2025 (não vistos pelo modelo durante o treino) para simular o desempenho em produção e validar a estabilidade temporal.
 - Teve-se o cuidado de retirar o overlap de clientes que apareciam no treino e no OOT, mantendo somente do treino:

BASES BRUTAS:

PÚBLICO TOTAL

Linhas totais: 3,795,310

CPFs únicos: 3,590,459 (Treino + OOT)

PÚBLICO TREINO (202410, 202411, 202412, 202501)

Total registros: 2,559,448

Total CPFs únicos: 2,462,481

PÚBLICO OOT

Total registros OOT: 1,235,862

Total CPFs únicos: 1,216,530

Shape final: (338918, 589) - **ANÁLISE DE SWAP IN**

Shape pos-trat: (338918, 1314) - MODELO TRABALHA COM 50

SAFRA

202503 177935

202502 160983

CPFs únicos: 333.435 (REPROVADOS)

Volume Aprovados (Fev/Mar): 770724

CPFs Aprovados (Fev/Mar): 766247

Volume Controle (Fev/Mar): 34938

CPFs Controle (Fev/Mar): 34339

BASES LIMPAS:

- CPFs em TREINO e OOT simultaneamente: 88,552 → **Decisão manter somente os de treino**
- **88.552 CPFs no TREINO e removidos do OOT**, pois o objetivo da validação OOT é simular o comportamento do modelo em dados genuinamente novos — clientes que o modelo já "viu" durante o treino não representam um cenário real de produção e inflam artificialmente as métricas de validação.
- **BASES FINAIS:**
 - **TREINO mantido: 2,462,481**
 - **OOT original: 1,216,530 (Rep + Apr + Con)**
 - **OOT limpo: 1,127,978 (Rep + Apr + Con)**
 - **Removidos do OOT: 88,552**
 - **Volume OOT (Fev/Mar) após filtro: 801.581 (Sem reprovados) CPFs únicos: 796793**

6. Avaliação de Desempenho e Resultados

6.1. Métricas Utilizadas

A escolha das métricas baseou-se na necessidade de avaliar tanto o poder discriminativo quanto a estabilidade:

- * **AUC ROC (Area Under the Curve):** Medida global de desempenho independente do corte.
- * **Gini Coefficient:** Derivado do AUC ($2 \times \text{AUC} - 1$), padrão da indústria de crédito para avaliar discriminação.
- * **KS (Kolmogorov-Smirnov):** Mede a máxima separação entre as distribuições de Bons e Maus. Essencial para definir pontos de corte operacionais.
- * **PSI (Population Stability Index):** Mediu a estabilidade da distribuição de scores entre o período de Treino e OOT. Valores abaixo de 0.1 indicam estabilidade excelente.

6.2. Resultados Alcançados (Modelo Final V6)

- * Desempenho Discriminativo (OOT):
 - * AUC: 0.7437
 - * Gini: 0.4874
 - * KS: 0.3567

* Benchmark: O modelo superou o benchmark anterior (KS 0.33) em aproximadamente 9%, validando a eficácia das novas features comportamentais.

* Estabilidade:

* PSI: 0.0180 (Classificação: Excelente). O modelo manteve o comportamento estável entre Janeiro e Março.

* Gap Treino vs OOT: A diferença de Gini (~ 0.06) indica um modelo equilibrado, sem sinais severos de overfitting.

6.3. Análise de Decis

A análise dos decis na base OOT demonstrou monotonicidade perfeita na taxa de maus:

* Decil 1 (Score Baixo): Taxa de Maus $\sim 3.5\%$.

* Decil 10 (Score Alto): Taxa de Maus $\sim 51.8\%$.

Isso prova que o modelo ordena o risco de forma eficaz, permitindo políticas de corte claras.

7. Conclusão

O modelo V6 Final, baseado na arquitetura LightGBM e enriquecido com engenharia de features comportamentais (Books), apresentou desempenho sólido e estabilidade temporal. A abordagem de seleção das Top 50 features garantiu um modelo enxuto, interpretável e pronto para implementação em produção, atendendo aos requisitos de segurança e performance para a concessão de crédito em cenário de migração.

Arquitetura de Data Lake com Camada Analítica e Monitoramento de Modelo

Oracle Cloud Infrastructure (OCI)

1. Visão Geral da Arquitetura

Esta arquitetura implementa um **Data Lake orientado a eventos**, com processamento distribuído e camada analítica integrada na Oracle Cloud Infrastructure.

O objetivo é permitir ingestão automatizada de dados, processamento escalável, organização em múltiplas camadas e consumo analítico com suporte ao ciclo completo de Machine Learning.

Principais capacidades da arquitetura:

- Ingestão automatizada de dados provenientes de ambiente **on-premises**
- Processamento distribuído com **Apache Spark (OCI Data Flow)**
- Organização em múltiplas camadas de dados
Landing → Bronze → Silver → Gold → Fabric
- Consumo analítico via **Oracle Autonomous Data Warehouse (ADW)**
- Visualização de dados com **Data Visualization nativo do ADW**
- Desenvolvimento e deploy de modelos via **OCI Data Science**
- Monitoramento operacional e estatístico de modelos em produção

A arquitetura utiliza conectividade privada baseada em:

- **FastConnect**
- **Dynamic Routing Gateway (DRG)**
- **Virtual Cloud Network (VCN)**

- **Service Gateway**

Essa configuração garante **isolamento de rede e segurança**, evitando exposição pública da ingestão de dados.

2. Extração de Dados (On-Premises → OCI)

2.1 Conectividade

A extração de dados ocorre a partir do **Data Center On-Premises**, utilizando conectividade privada para a OCI. DRG (Dynamic Routing Gateway) — ponto de terminação do FastConnect dentro da VCN, roteando tráfego on-premises para as subnets privadas via Service Gateway.

Componentes envolvidos:

- FastConnect
- Dynamic Routing Gateway (DRG)
- Virtual Cloud Network (VCN)
- Service Gateway

Esse modelo garante que **os dados trafeguem apenas por rede privada**, sem exposição pública.

2.2 Camada Landing

A camada Landing é o primeiro ponto de armazenamento no ambiente cloud.

Lifecycle policy configurada: retenção máxima de 90 dias, com transição automática para Archival Storage após 30 dias, atendendo requisitos de LGPD para dados brutos de CPF.

Destino:

OCI Object Storage – Bucket Landing

Características:

- Armazenamento bruto
- Sem qualquer transformação
- Estrutura de diretórios padronizada
- Particionamento por domínio e safra
- Função exclusiva de aterrissagem de dados

Objetivo principal:

Garantir **rastreabilidade, reprocessamento e auditoria dos dados ingeridos**.

3. Disparo Automático (Event-Driven)

A arquitetura utiliza um modelo **orientado a eventos**.

3.1 OCI Events

Quando um novo arquivo é gravado no **Bucket Landing**, o serviço **OCI Events** dispara automaticamente um evento.

3.2 OCI Functions

Uma função serverless executa as seguintes tarefas:

- Validação da nomenclatura do arquivo
- Extração de metadados (dataset, safra, domínio)
- Verificação de idempotência
- Registro inicial do processamento
- Chamada da pipeline no **OCI Data Integration via API REST**

Objetivo:

Garantir que o processamento seja iniciado **apenas quando necessário**.

4. Orquestração – OCI Data Integration

O **OCI Data Integration** atua como **orquestrador central das pipelines de dados**.

4.1 Pré-Validações

Antes de iniciar o processamento, são realizadas validações:

- Verificação da presença de arquivos esperados
- Validação de schema
- Validação de tamanho mínimo
- Verificação de duplicidade

4.2 Controle Operacional

O controle operacional da pipeline é armazenado no **Oracle Autonomous Data Warehouse (ADW)**.

Tabela: `pipeline_runs`

Armazena histórico das execuções:

- dataset
- safra
- status
- timestamps
- rowcount
- tempo total de execução

Tabela: `pipeline_state`

Responsável por controle de idempotência.

Campos principais:

- dataset
- partição
- estágio
- status atual

4.3 Disparo do Processamento

Após validação, o Data Integration dispara jobs no:

OCI Data Flow (Spark)

Utilizando **parâmetros dinâmicos** para dataset e safra.

5. Processamento Distribuído – OCI Data Flow

O **OCI Data Flow** executa o processamento distribuído utilizando Apache Spark.

Ele promove dados entre as diferentes camadas do Data Lake.

5.1 Landing → Bronze

Objetivo:

Persistir os dados brutos em formato estruturado.

Lifecycle policy configurada: retenção de 180 dias em Standard Storage, com arquivamento posterior. Dados em formato Parquet garantem auditabilidade sem necessidade de manter a landing ativa.

Características:

- Conversão para **Parquet**
- Particionamento por safra
- Garantia de auditabilidade

- Nenhuma regra de negócio aplicada

5.2 Bronze → Silver

Nesta camada ocorre o tratamento inicial dos dados.

Atividades realizadas:

- Limpeza de dados
- Deduplicação
- Normalização
- Integração entre múltiplas fontes
- Aplicação de regras básicas de qualidade

Transformações típicas:

- Tratamento de datas
- Conversão de tipos
- Joins estruturais

5.3 Silver → Gold

A camada Gold contém **dados curados e prontos para consumo analítico**.

Características:

- Modelagem analítica
- Agregações por cliente ou produto
- Criação de datasets prontos para BI e Machine Learning
- Particionamento otimizado para consulta

5.4 Gold → Store

A camada Fabric organiza os dados por domínio analítico e modelagem. Ponto de serving do modelo via Data Flow (batch scoring).

Elementos presentes:

- ABTs (Analytical Base Tables)
- Feature sets
- Book de variáveis
- Estruturas para modelagem

Estrutura lógica:

STORE

└─ dominio.bureau

└─ dominio.comportamento

└─ dominio.score

└─ dominio.modelo

6. Consumo Analítico

6.1 Oracle Autonomous Data Warehouse (ADW)

O ADW atua como **camada analítica central da arquitetura**.

Funções:

- Execução de consultas SQL analíticas
- External Tables lendo diretamente do Object Storage
- Persistência de métricas de monitoramento
- Armazenamento de tabelas operacionais

6.2 Visualização de Dados – ADW Data Visualization

A visualização analítica é realizada utilizando a **ferramenta de Data Visualization nativa do ADW** (Oracle Database Actions).

Funcionalidades:

- Criação de dashboards interativos
- Análise exploratória de dados
- Visualização de métricas operacionais
- Monitoramento de performance de modelos
- Integração direta com tabelas do ADW

Benefícios:

- Redução de custo operacional (dispensa OAC)
- Integração nativa com o banco analítico
- Menor latência de consulta
- Governança centralizada

6.3 OCI Data Science

O serviço OCI Data Science é responsável pelo ciclo de vida de modelos. O serving do modelo ocorre via OCI Data Flow (batch scoring periódico), consumindo os feature sets da camada Fabric e gravando as predições na camada Store.

Funções:

- Desenvolvimento de modelos
- Treinamento
- Deploy
- Versionamento

- Integração com dados das camadas Gold e Fabric

7. Monitoramento Operacional

Responsável principal: **Engenharia de Dados / MLOps**

Métricas monitoradas:

- SLA por etapa
- Tempo de processamento
- Volume de dados processados
- Falhas e retries
- Status por dataset ou safra

Fontes de monitoramento:

- tabela pipeline_runs
- tabela pipeline_state
- logs do Data Flow

8. Monitoramento da Qualidade dos Dados

Executado nas camadas **Silver e Gold**.

Métricas avaliadas:

- Taxa de preenchimento
- Validação de tipo
- Verificação de faixas permitidas
- Validação de domínio de variáveis categóricas
- Comparação estatística de distribuições

Indicadores analisados:

- média
- mediana
- desvio padrão
- mínimo
- máximo

Persistência no ADW:

Tabela:

`data_quality_metrics`

9. Monitoramento do Modelo (MLOps)

Após o deploy do modelo, seu comportamento é monitorado continuamente. As métricas são calculadas via OCI Data Science (jobs agendados) e OCI Data Flow (grande volume), persistidas no ADW e monitoradas continuamente pelo OCI Monitoring com alarmes configurados sobre as tabelas “model_monitoring_metrics” e “data_drift_metrics”. Quando um limiar é violado — queda de AUC, PSI acima de 0.20 ou KS abaixo do mínimo aceitável — o OCI Notifications dispara alertas automáticos para o time de MLOps via e-mail ou integração com PagerDuty.

As métricas são calculadas via:

- **OCI Data Science**
- **OCI Data Flow**

e persistidas no **ADW**.

9.1 Data Drift (Entrada)

Verifica mudanças nas variáveis de entrada.

Métricas:

- PSI por variável
- KS por variável
- Mudança de média
- Mudança de desvio padrão

Tabela:

data_drift_metrics

Granularidade:

modelo + variável + safra

9.2 Concept Drift (Saída)

Avalia se a relação **variáveis** → **target** mudou.

Métricas:

- AUC
- KS
- Lift
- performance por segmento

Tabela:

model_monitoring_metrics

Granularidade:

modelo + safra

9.3 Monitoramento de Predição

Monitora a estabilidade das predições.

Indicadores:

- distribuição de score
- taxa de aprovação
- taxa de recusa
- estabilidade numérica

Tabela:

`prediction_distribution_metrics`

9.4 Execução dos Cálculos

Os cálculos podem ocorrer em dois pontos:

OCI Data Science

- notebooks automatizados
- jobs agendados
- cálculo de métricas estatísticas

ou

OCI Data Flow

- processamento distribuído
- cálculo de métricas em grande volume

9.5 Visualização das Métricas

Os dashboards são construídos diretamente no **ADW Data Visualization**, consumindo as tabelas:

- `model_monitoring_metrics`
- `data_drift_metrics`
- `prediction_distribution_metrics`

Dashboards típicos:

- saúde geral do modelo
- evolução de AUC por safra
- heatmap de PSI por variável
- distribuição de score performance por parceiro

10. Segurança e Governança

A arquitetura adota um modelo de **defesa em profundidade**, com múltiplas camadas de segurança. NAT Gateway: permite saída controlada das subnets privadas para internet (downloads de bibliotecas e atualizações de runtime), sem expor os recursos internos a conexões de entrada

Componentes principais:

- IAM (Identity and Access Management)
- Compartments
- OCI Vault
- Cloud Guard
- Security Zones
- Web Application Firewall (WAF)

Princípios adotados:

- Zero Trust
- menor privilégio

- criptografia em repouso
- criptografia em trânsito
- monitoramento contínuo

11. Conclusão

A arquitetura proposta garante:

- automação ponta a ponta
- ingestão segura de dados
- processamento escalável
- governança e rastreabilidade
- consumo analítico performático
- monitoramento estatístico de modelos

Ela transforma o modelo de Machine Learning de um **artefato isolado** em um **sistema vivo, monitorado e auditável**, capaz de evoluir continuamente.